



北京外国语大学

硕士学位论文

论文题目：面向低资源语种的自动语音评测系统
设计与开发——以斐济语为例

学 号：202320230003

姓 名：骆雨萌

导 师：唐锦兰 王士进

研究方向：计算机辅助外语教学

学 科：教育技术学

培养单位：人工智能与人类语言重点实验室

2026 年 3 月 15 日

北京外国语大学学位论文原创性声明和使用授权说明

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果，也不包含为获得北京外国语大学或其他教育机构的学位或证书撰写的或使用过的材料。对本文的研究做出重要贡献的个人和集体，均已在论文中以明确方式标明。本声明的法律结果由本人承担。

论文作者签名：

日期： 年 月 日

学位论文使用授权说明

本人完全了解北京外国语大学关于收集、保存、使用学位论文的规定，即： 按照学校要求提交学位论文的印刷本和电子版本；

学校有权保存学位论文的印刷本和电子版，并提供目录检索与阅览服务；

学校可以采用影印、缩印、数字化或其它复制手段保存论文；

学校可以公开论文的全部或部分内容。

论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月

摘 要

语音教学是外语教学中的基础环节，其效果依赖学习者在持续练习中不断获得外部反馈、进行自我监控并逐步修正发音偏差。低资源语种（Less-Commonly Taught Languages）语音教学在资源、技术工具及学习支持上存在明显不足，传统教师人工纠音模式难以满足个性化、持续性需求；自动语音评测技术虽在高资源语言中广泛应用，但受限于大规模发音纠错标注语料，无法直接迁移至低资源场景，且缺乏发音错误细粒度诊断与教学指导性反馈，制约了其在低资源语种语音教学中的应用。

针对上述问题，本研究以斐济语为研究对象，围绕低资源语种自动语音评测系统的设计与开展研究，提出一种结合音频文本强制对齐与声学特征匹配的语音评测方法——MFA-GFCC-DTW，通过提取语音信号的声学特征并计算学习者语音与标准语音之间的特征相似度，实现学习者发音准确度的自动评估；在此基础上，构建了句级、词级与音素级相结合的多层次评测机制，实现对学习者发音问题的细粒度定位与诊断；同时，设计了基于大语言模型的可解释反馈生成机制，将抽象的评分指标转化为自然语言反馈信息，提升了评测结果的可理解性与教学指导价值。

为进一步探究评测算法在教学场景中的应用效果，本研究设计并开发了一套支持细粒度发音诊断的语音评测原型系统，并将系统应用于斐济语学习场景，同时通过问卷调查方式收集学习者反馈。结果表明，学习者对该评测系统的细粒度诊断信息与解释性反馈机制整体评价较为积极，系统能够有效帮助学习者定位发音问题、理解自身发音偏差，验证了本研究提出的技术路径对于提升低资源语种学习者发音质量的实际价值。

本研究的创新点体现在如下四方面：（1）构建了支持斐济语语音评测的基础资源体系，包括多模态平行语料库、发音词典与声学模型；（2）提出了基于MFA-GFCC-DTW的自动语音评测方法，实现了句级-词级-音素级多层次发音诊断；（3）设计了基于大语言模型（Large Language Model, LLM）的可解释反馈生成机制，为低资源语种自动语音评测系统的设计与实现提供了一种可行技术路径。

关键词：低资源语种；自动语音评测；细粒度发音诊断；计算机辅助语言教学

Abstract

Pronunciation instruction is a fundamental component of foreign language teaching, relying on continuous practice, external feedback, and learner self-monitoring. Compared with high-resource languages such as English and Chinese, pronunciation teaching for low-resource languages still lacks sufficient instructional resources and technological support. Traditional instruction mainly depends on teacher demonstrations and classroom correction, which limits the availability of continuous and individualized feedback. Although automatic pronunciation assessment has been widely applied in high-resource language learning, existing approaches often rely on large-scale speech corpora and mature acoustic models and therefore are difficult to apply directly to low-resource language contexts.

To address these issues, this study takes Fijian as the research object and explores the design and development of an automatic pronunciation assessment system for low-resource languages. First, a foundational resource framework was constructed, including a speech corpus, a pronunciation dictionary, and an acoustic model. Based on these resources, a pronunciation assessment method named MFA-GFCC-DTW was proposed by combining forced alignment with acoustic feature matching. The method extracts GFCC features from speech signals and calculates the similarity between learner speech and reference speech to evaluate pronunciation accuracy. A multi-level assessment mechanism integrating sentence-, word-, and phoneme-level evaluation was further developed to support fine-grained localization of pronunciation errors. In addition, an explainable feedback mechanism based on large language models was designed to transform scoring indicators into natural-language feedback.

To examine its instructional application, a pronunciation assessment prototype system supporting fine-grained diagnosis was developed and applied in Fijian learning scenarios. Learners' feedback was collected through questionnaires and interviews. The results show that the system effectively helps learners identify pronunciation problems and understand their pronunciation deviations, demonstrating the practical value of the proposed approach for improving pronunciation learning in low-resource languages.

Keywords: less-commonly taught languages; automatic pronunciation assessment; fine-grained pronunciation diagnosis; computer-assisted language learning (CALL)

目 录

北京外国语大学学位论文原创性声明和使用授权说明	i
摘 要	ii
Abstract	iii
第 1 章 绪论	1
1.1 研究背景	1
1.1.1 低资源语种语音教学的现实困境	1
1.1.2 自动语音评测技术的发展与局限	2
1.2 研究意义	4
1.3 研究内容与创新点	4
1.3.1 研究内容	5
1.3.2 研究创新点	6
1.4 论文结构	6
第 2 章 文献综述	8
2.1 核心概念	8
2.1.1 低资源语种	8
2.1.2 语音教学	8
2.1.3 自动语音评测	8
2.2 语音教学的相关理论	9
2.2.1 技能习得理论	9
2.2.2 形成性评价理论	10
2.2.3 Hattie & Timperley 的反馈模型	12
2.2.4 元认知调节	13
2.3 自动语音评测技术路径	14
2.3.1 基于特征比较的传统语音评测	14
2.3.2 基于声学模型的音素级语音评测	15
2.3.3 基于深度学习的端到端语音评测	16
2.4 低资源语种语音评测研究现状	18
2.5 研究评述	20
第 3 章 研究设计	22
3.1 研究思路	22
3.2 研究方法	23

3.2.1 开发研究法	23
3.2.2 问卷调查法	24
3.3 研究情境与研究对象	24
3.3.1 研究情境	24
3.3.2 研究对象	25
3.4 研究流程	26
3.4.1 斐济语语音评测资源构建	26
3.4.2 语音评测方法设计	26
3.4.3 语音评测原型系统开发	27
3.4.4 教学应用验证	27
3.5 数据收集工具	28
3.5.1 问卷设计	28
3.5.2 问卷内容	29
3.6 数据分析方法	30
第 4 章 低资源语种语音评测系统设计与实现	32
4.1 斐济语语音教学需求分析	32
4.1.1 斐济语语音教学特点	32
4.1.2 语音练习与细粒度评测反馈需求分析	32
4.1.3 评测维度与指标设计	33
4.2 系统总体架构设计	34
4.2.1 系统设计目标	34
4.2.2 系统总体架构	35
4.2.3 系统关键功能模块设计	36
4.3 语音评测关键技术实现	37
4.3.1 基于 MFA 的语音—文本强制对齐	37
4.3.2 基于 GFCC 的声学特征提取	39
4.3.3 基于 DTW 的相似度计算与评分生成	40
4.3.4 算法流程伪代码	43
4.4 细粒度反馈生成机制	44
4.4.1 评测结果的结构化与诊断决策	44
4.4.2 基于 LLM 的自然语言反馈生成	45
第 5 章 教学验证	48
5.1 应用实施过程	48

5.2 语音评测案例分析	49
5.3 问卷结果分析	50
第 6 章 总结与展望	52
6.1 本文研究工作总结	52
6.2 未来展望	53
参考文献	54
1. 英文文献	54
2. 中文文献	58

第 1 章 绪论

1.1 研究背景

1.1.1 低资源语种语音教学的现实困境

语音教学是外语教学中的基础环节，是影响学习者口语可理解性、交际有效性与语言自信的重要因素。与词汇、语法等偏重陈述性知识的学习不同，语音学习更具有明显的技能属性，其发展依赖学习者在持续练习中不断获得外部反馈、进行自我监控并逐步修正发音偏差。形成性评价理论指出，嵌入学习过程之中的频繁反馈与诊断，比单纯在学习结束后给出结果判断更能促进学习表现的提升¹。反馈之所以能够促进学习，并不只是因为它告诉学习者“结果如何”，更重要的是它能够帮助学习者识别当前表现与目标之间的差距，并为后续改进提供方向²。Derwing 和 Munro 在其有关发音教学的经典论文中指出，语音训练在外语教学中不应被边缘化，学习者需要基于研究证据的发音指导。换言之，语音学习的关键不只是“多听多练”，而是通过有针对性的反馈帮助学习者识别错误位置、理解偏误性质，并逐步形成可迁移的发音控制能力，否则练习往往容易停留在机械重复层面，既难以准确发现问题，也难以实现有效改进。³

然而，上述以持续反馈支撑语音习得的教学条件，在低资源语种场景中往往难以得到充分保障。Gor 和 Vatz 针对 Less commonly taught languages (LCTs) 面临的教育问题进行了研究，指出这类语种在课程建设、教材供给、师资配置、学习支持和评估体系等方面普遍处于相对弱势地位，学习者能够接触到的标准化教学资源与高频练习机会明显少于主流外语学习者⁴。这一问题在语音教学中尤为突出：一方面，低资源语种教师和母语者资源有限，难以为学习者提供高频、细致、个别化的发音纠正；另一方面，学习者在课堂之外可利用的标准音频、跟读材料和自主练习支持不足，导致其虽能进行有限模仿，却难以获得稳定、明确的纠错依据。以近年来的低资源语种移动学习实践为例，虽然数字平台能够在一定程度上扩展学习机会，但也同时反映出这

¹ Black, P., & Wiliam, D. (1998). Assessment and classroom learning. *Assessment in Education: principles, policy & practice*, 5(1), 7-74.

² Hattie, J., & Timperley, H. (2007). The power of feedback. *Review of Educational Research*, 77(1), 81-112.

³ Derwing, T. M., & Munro, M. J. (2005). Second language accent and pronunciation teaching: A research-based approach. *TESOL quarterly*, 39(3), 379-397.

⁴ Gor, K., & Vatz, K. (2009). Less commonly taught languages: Issues in learning and teaching. *The handbook of language teaching*, 234-249.

类语种在教学资源组织、学习支持和个性化反馈方面仍面临现实约束。⁵

随着信息技术与人工智能技术的发展,数字技术已成为语言学习环境变革的重要力量,计算机辅助外语教学(Computer-Assisted Language Learning, CALL)的研究证明了计算机技术能够突破传统课堂在时间、空间与教学规模上的限制,重构语言学习中的输入、练习与反馈方式⁶;在语音教学领域,计算机辅助发音训练(Computer-Assisted Pronunciation Training, CAPT)的发展进一步显示出其重要的教学潜力。对于低资源语种而言,面临师资稀缺、语言资源有限而导致个性化反馈不足的现状,自动语音评测可以作为教师反馈能力的有效延伸与补充,极大地扩展个别化语音指导的时间与空间,因此,探索更适合低资源语种语音教学场景的数字化反馈方案,成为当前教育技术研究中具有现实针对性的重要议题。⁷

1.1.2 自动语音评测技术的发展与局限

自动语音评测(Automatic Pronunciation Assessment)是CAPT中的关键技术之一,通过对学习者语音信号进行声学特征分析与模型匹配,对其发音准确性、流利度或整体发音质量进行自动评价,从而为学习者提供即时反馈和练习支持⁸。近年来,一些商业语言学习平台(如Duolingo、Rosetta Stone等)已将自动语音评测功能嵌入学习流程,使学习者能够通过跟读练习获得即时反馈,从而提升语音训练的自主性与连续性;越来越多的语言考试(如TOFEL、AZELLA等)也开始采用自动语音评测算法来辅助口语能力部分的测试。与依赖教师反馈的传统语音教学课堂模式相比,自动语音评测能够在较低成本下为大量学习者提供持续、规模化且相对一致的评估服务,在改善学习者发音表现方面具有积极作用,逐渐成为数字语言学习环境中的重要组成部分⁹。

自动语音评测的技术发展路径大体经历了从传统声学模型方法到深度学习方法的演进。早期研究主要通过比较学习者语音与标准发音之间的声学差异来评估发音质量。其中,Witt和Young提出的Goodness of Pronunciation(GOP)算法被认为是自动语音评测领域的重要基础方法之一,该算法利用声学模型来计算学习者发音与目标音素之间的似然差异,从而获得音素级发音评分,为后续大量研究提供了重要技术框

⁵ Tang, J., Zhai, Y., Li, L., Liu, P., & Deng, H. (2025). Mobile learning for less-commonly taught languages: design and application. *Journal of China Computer-Assisted Language Learning*, 5(1), 23-55.

⁶ Warschauer, M., & Healey, D. (1998). Computers and language learning: An overview. *Language teaching*, 31(2), 57-71.

⁷ Rogerson-Revell, P. M. (2021). Computer-assisted pronunciation training (CAPT): Current issues and future directions. *Relc Journal*, 52(1), 189-205.

⁸ Isaacs, T., & Harding, L. (2017). Pronunciation assessment. *Language Teaching*, 50(3), 347-366.

⁹ Neri, A., Mich, O., Gerosa, M., & Giuliani, D. (2008). The effectiveness of computer assisted pronunciation training for foreign language learning by children. *Computer Assisted Language Learning*, 21(5), 393-408.

架¹⁰。随着语音识别技术的发展，研究者进一步引入深度神经网络、卷积神经网络以及端到端模型对发音错误检测与诊断（Mispronunciation Detection and Diagnosis, MDD）任务进行建模，显著提升了自动语音评测的准确性^{11,12}。尽管自动语音评测技术在近年来取得了快速发展，但现有研究和应用仍主要集中在英语等高资源语言环境中，这类语言通常拥有规模较大的语音语料库、较完善的发音词典以及成熟的声学模型等资源，为自动语音评测系统的训练与优化提供了重要基础¹³。然而，低资源语言通常缺乏大规模语音数据、系统化发音词典以及发音错误标注语料，这不仅限制了语音识别模型的训练，也使得依赖数据驱动的深度学习评测方法难以直接迁移¹⁴。因此，在低资源语种场景中，如何在有限语料条件下构建有效的语音评测方法，成为自动语音评测研究面临的重要问题。

在教育应用层面，虽然部分语言学习平台已经开始尝试将自动语音评测技术应用于低资源语种教学，但其实现方式往往仍基于面向高资源语言设计的通用算法框架，难以充分适应低资源语种在语音结构、语料规模方面的差异。在北外多语智慧学习平台的实践中¹⁵，语音评测模块已被应用于斐济语等低资源语种课程，通过对学习者跟读音频进行分析，给出基本的发音评估结果。然而，现有系统的反馈粒度相对有限，难以对学习者的发音错误进行更细致的定位和诊断。

在缺乏大量标注语料的条件下，如何充分利用已有文本信息和有限语音资源，提高评测系统的反馈精度与教学适用性，仍然是有待进一步探索的问题。基于此背景，本文以某高校多语智慧学习平台斐济语模块为研究场景，在现有语音评测框架基础上探索适用于低资源语种的优化路径。通过在有限语料条件下引入更具鲁棒性的声学特征与文本对齐方法，尝试实现更细粒度的发音评估与反馈机制，以期为低资源语种语音教学提供更加有效的技术支持。

¹⁰ Witt, S. M., & Young, S. J. (2000). Phone-level pronunciation scoring and assessment for interactive language learning. *Speech communication*, 30(2-3), 95-108.

¹¹ Leung, W. K., Liu, X., & Meng, H. (2019, May). CNN-RNN-CTC based end-to-end mispronunciation detection and diagnosis. In *ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 8132-8136). IEEE.

¹² Li, K., Qian, X., & Meng, H. (2016). Mispronunciation detection and diagnosis in 12 english speech using multidistribution deep neural networks. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 25(1), 193-207

¹³ Besacier, L., Barnard, E., Karpov, A., & Schultz, T. (2014). Automatic speech recognition for under-resourced languages: A survey. *Speech communication*, 56, 85-100.

¹⁴ Adda, G., Stüker, S., Adda-Decker, M., Ambourou, O., Besacier, L., Blachon, D., ... & Zerbib, S. (2016). Breaking the unwritten language barrier: The BULB project. *Procedia Computer Science*, 81, 8-14.

¹⁵ Tang, J., Zhai, Y., Li, L., Liu, P., & Deng, H. (2025). Mobile learning for less-commonly taught languages: design and application. *Journal of China Computer-Assisted Language Learning*, 5(1), 23-55.

1.2 研究意义

本文的研究意义可以从理论意义、技术意义、实践意义三个方面展开论述。

从理论层面来看，本文有助于丰富低资源语音教学中的教学理论与语音评测技术融合的研究视角。基于形成性评价、技能习得理论等多个教学理论支撑，本文将自动语音评测的功能定位从单纯的“发音打分”拓展为“诊断反馈”，通过句级、词级和音素级多层次评测结果，为学习者提供更具针对性的发音问题定位，并进一步借助自然语言反馈提升评测结果的可理解性，由此，在低资源语种语音教学情境中探索了“评测—反馈—修正—再练习”的形成性学习闭环，为自动语音评测技术与语音教学理论的融合提供了具体案例。

从技术层面来看，本文为低资源语种自动语音评测提供了一种可行路径。当前自动语音评测技术在英语、汉语等高资源语种中已取得较大发展，能够在一定程度上实现较高精度的发音评分与错误诊断，然而，这类方法往往依赖大规模语音数据、发音词典、发音错误标注语料等，对于斐济语这类低资源语种而言，上述资源条件并不充分，难以直接迁移。针对这一痛点，本文设计的基于 MFA-GFCC-DTW 的自动语音评测方法，充分利用了“已知文本+标准语音”的朗读评测场景，在不依赖大规模发音偏误标注语料的条件下实现句级、词级和音素级发音评估，该技术路径为低资源语种在缺少大规模标注语料时开展自动语音评测提供了可行参考。

从教学实践层面来看，本文设计的语音评测系统原型，能够为低资源语种学习者提供更具针对性的自主语音练习支持，并为多语智慧学习平台的功能优化提供依据。斐济语在国内高校外语教学体系中属于学习群体较小、课程资源相对有限的语种，能够同时具备斐济语基础、参与系统试用并完成语音任务的学习者数量较少，基于上述现实条件，本文开展了小样本量教学验证，在真实低资源语种学习情境中完成原型系统设计、功能实现与初步应用验证，也为其他低资源语种的语音练习模块建设提供了可迁移的设计思路。

1.3 研究内容与创新点

针对当前低资源语种语音教学中缺乏有效自动语音评测工具的问题，本文以斐济语为研究对象，在分析现有自动语音评测技术特点与局限的基础上，构建支持斐济语语音评测的基础资源，并设计面向低资源语种的语音评测方法与细粒度反馈机制，在此基础上开发原型系统并在教学场景中进行初步应用验证，以探索自动语音评测技术在低资源语种语音教学中的应用价值。本文的主要研究内容与创新点如下。

1.3.1 研究内容

（一）低资源语种语音评测技术现状分析。本文对当前自动语音评测技术的发展现状进行系统梳理，重点分析不同技术路径在语音评测任务中的应用特点与局限；结合低资源语种在语音数据规模、语音资源建设以及模型训练条件等方面的现实约束，及其语音教学需求，分析现有语音评测方法在低资源语种应用中的适配性问题，总结当前语音评测系统在资源依赖程度、评测粒度以及反馈可解释性等方面存在的不足，为后续面向斐济语的语音评测方法设计提供理论依据与技术参考。

（二）斐济语语音评测基础资源构建。针对低资源语种语音评测面临的基础资源不足问题，本文结合斐济语语音教学材料，构建支持语音评测任务的基础资源体系，包括斐济语发音词典、标准朗读语音语料以及相应平行文本；在此基础上利用 Montreal Forced Aligner (MFA) 工具构建语音与文本之间的强制对齐模型，实现语音信号与音素序列之间的自动对齐。通过上述资源构建与工具配置，为后续语音评测算法的实现提供必要的数据库和技术支撑，同时也为斐济语语音教学研究积累可复用的语音资源。

（三）基于 MFA-GFCC-DTW 的语音评测方法与细粒度反馈生成机制设计。本文在传统基于声学特征匹配的语音评测框架的基础上进行优化，构建了基于 MFA-GFCC-DTW 的混合式语音评测框架。针对真实移动学习环境中背景噪声干扰的问题，引入抗噪性更强的伽马通频率倒谱系数 (Gammatone Frequency Cepstral Coefficients, GFCC) 算法替代梅尔频率倒谱系数 (Mel-Frequency Cepstral Coefficient, MFCC) 算法进行特征提取；结合 MFA (Montreal Forced Aligner) 音素级强制对齐算法与动态时间规整 (Dynamic Time Warping, DTW) 算法，实现句级、词级及音素级的细粒度错误定位。此外，为跨越底层声学数据与教学指导之间的鸿沟，本文进一步设计了细粒度反馈生成机制：将上述结构化评测结果作为输入，通过提示工程 (Prompt Engineering) 调用大语言模型 (LLM)，生成面向学习者的自然语言反馈，从而将底层声学指标转化为具有教学指导意义的解释性反馈。

（四）在斐济语教学中的应用验证。本文设计并落地斐济语语音评测原型系统，实现面向学习者的语音跟读评测功能，能够对学习者朗读指定文本的语音进行自动评测，并提供句级评分、词级评分及错误定位反馈。在此基础上，通过组织学习者进行系统试用，并通过问卷调查对系统的可用性、反馈有效性以及学习体验初步评估，从而探索自动语音评测技术在低资源语种语音教学中的应用价值，并为后续系统优化提供参考依据。

1.3.2 研究创新点

（一）技术路径创新：提出了面向低资源语种的细粒度语音评测实现路径。针对低资源语种的现实困境，本文基于传统基于声学特征匹配的语音评测方法，创新性地融合了抗噪性更强的 GFCC 特征工程与 MFA 文本语音强制对齐技术，在无需发音偏差标注数据的前提下实现单词级与音素级的细粒度错误定位，能够更加精确地指出学习者可能存在发音偏差的位置，为低资源语种自动语音评测系统的构建提供了一种可行的技术方案。

（二）反馈机制创新：设计了 LLM 赋能的语音评测解释性反馈生成机制。传统的语音评测系统多停留在输出“得分”或“标红错误音素”的浅层结果，存在反馈形式单一、解释性不足的问题。本文探索将大语言模型引入语音评测反馈生成过程，设计了“声学指标—自然语言”的细粒度反馈生成机制，将句级评分、词级评分以及音素级错误定位等结构化声学评测结果输入大语言模型，结合大模型提示词工程（Prompt Engineering），生成面向学习者的自然语言反馈，从而将结构化声学指标转化为具有教学指导意义的解释性反馈，提高语音评测系统在语言学习情境中的可理解性与教学支持能力。

（三）资源构建与教学应用创新：丰富了斐济语语音评测的数字化资源基础与应用实践。本文构建了支持斐济语语音评测的多模态平行语料库、声学模型与发音词典，为该语种提供了基础资源与技术探索；同时，将优化后的评测技术嵌入到多语智慧学习平台的真实教学情境中，不仅提升了学习者的自主纠音体验，也为非通用语种解决“师资短缺、个性化指导不足”的现实困境提供了一种可行的技术应用路径。

1.4 论文结构

本论文结构安排如下：

第一章 绪论。本章首先阐述本研究的选题背景与研究意义，从低资源语种语音教学面临的现实问题出发，分析当前自动语音评测技术在低资源语言教学中的应用局限，并基础上提出本文的研究问题、研究目标与研究意义；最后概述本文的研究内容与创新点，并对论文整体结构进行说明。

第二章 文献综述与相关理论基础。本章首先梳理自动语音评测技术的发展历程与主要技术路径，对当前常见的语音评测算法及其特点进行分析；其次从教育学视角介绍语音教学相关理论基础，包括技能习得理论与形成性评价理论等，并分析这些理论对语音评测反馈设计的启示；最后综述低资源语种语音评测研究现状，总结当前研究在资源建设、评测粒度以及反馈机制等方面存在的不足，为本文研究提供理论依据

与研究切入点。

第三章 研究设计。本章在前文研究问题与理论基础的基础上，介绍本研究的整体研究思路与技术路线；其次说明研究情境与研究对象，并阐述本研究所采用的研究方法，包括开发研究法与问卷调查法；最后介绍数据收集与分析方案，以及问卷的设计依据与问卷内容，为后续系统开发与教学应用验证提供研究设计依据。

第四章 低资源语种语音评测系统的设计与实现。本章介绍了低资源语种语音评测系统的整体架构与关键功能模块，详细阐述了基于 MFA-GFCC-DTW 的语音评测方法实现过程，包括语音强制对齐、声学特征提取与相似度计算等关键步骤；最后介绍了细粒度发音诊断与可解释反馈生成机制，以及语音评测原型系统的实现与运行流程。

第五章 教学应用验证。本章介绍了语音评测系统在斐济语学习场景中的应用方式与实验流程，并对问卷数据进行分析，探讨细粒度发音诊断与解释性反馈在语音学习中的应用价值。

第六章 总结与展望。本章对全文研究工作进行总结，概括本文在斐济语语音评测资源构建、细粒度评测方法设计、可解释反馈生成机制以及原型系统应用验证等方面的主要成果；同时，结合研究不足，从语音资源扩充、评分机制优化、系统功能完善以及跨语种迁移应用等方面提出未来研究方向。

第2章 文献综述

2.1 核心概念

2.1.1 低资源语种

目前领域内大多数研究对低资源语种译为 Under-Resourced Languages，指语言资源建设和语言技术开发方面处于不足状态的语言，这类语言往往缺乏系统的语言学研究专业人才、以及缺少用于语音和语言处理的电子资源。在本文的研究语境下，使用 Less-Commonly Taught Languages 这一概念¹⁶，即在提及“低资源语种”时更聚焦于教育场景中“教学资源稀缺的语言”（如斐济语、塔玛齐格特语、桑戈语等）这一指向。这类语言虽可能拥有大量母语使用者，但在国际交流和教育机构中较少被使用和教授，在教学资源（教材、工具、师资等）和应用场景上存在显著不足。

2.1.2 语音教学

本文研究所基于的某高校多语智慧学习平台的教学大纲中不涉及具体音标的教学，而是基于外语教学的自然教学法（Natural Approach）和沉浸式教学法（Immersion Method），通过情境模拟创建斐济语言环境，并根据语音评估和自适应学习提供足够的语言练习和即时反馈。因此，在本文的研究语境下，既聚焦于通过实时语音评估和反馈训练学生发音的准确性，也强调马秋武教授提出的“动态语音教学”概念¹⁷，即在情境应用中通过语流中的实际操练，帮助学习者掌握语音变化规律，包括语调（intonation）、重音（stress）、节奏（rhythm）、连读（linking）、停顿（pauses）等要素，而非孤立地训练单音准确性。

2.1.3 自动语音评测

自动语音评测任务通常可以根据是否提供参考文本划分为文本相关评测（text-dependent assessment）和文本无关评测（text-independent assessment）两类。文本相关评测主要面向朗读类任务，如字、词、句或篇章朗读，评测过程以给定文本为先验信息，通过分析学习者语音与目标文本之间的对应关系，对发音准确性、节奏或流利度等指标进行评估；而文本无关评测则主要针对口头表达类任务，如口头复述、

¹⁶ Tang, J., Zhai, Y., Li, L., Liu, P., & Deng, H. (2025). Mobile learning for less-commonly taught languages: design and application. *Journal of China Computer-Assisted Language Learning*, 5(1), 23-55.

¹⁷ 马秋武,翟海莹.动态语音教学：国际汉语语音教学的有效手段[J].汉语学习,2024,(01):73-83.

看图说话、话题陈述或口头翻译等，这类任务中学习者的语音内容事先未知，评测系统需要同时处理语音识别与语言表达质量评估等问题^{18,19,20}。

本文研究的是如何针对多语智慧学习平台的语音评测功能进行优化，该平台中的发音练习题型为“标准录音示范-学生跟读”，属于典型的文本相关朗读评测场景。因此，在本文的研究语境中，“语音评测”特指文本信息已知的朗读评测任务：系统通过对比学习者朗读给定文本的语音与母语者标准发音，对其发音准确性进行自动评估，并进一步实现单词级与音素级的错误读音检测与诊断。

2.2 语音教学的相关理论

2.2.1 技能习得理论

技能习得理论（Skill Acquisition Theory, SAT）是二语习得研究中一类以认知与复杂行为技能发展为中心的理论，认为语言能力并非单纯的规则记忆，而是与其他复杂技能（如体育、音乐演奏等）类似，都遵循一个共同的发展机制：学习者先在意识层面掌握规则或形式，然后在大量实践中将这种显性知识程序化，最终达到无需意识控制即可熟练执行的自动化阶段^{21,22}。这一观点将语言学习与一般技能获得过程联系起来，强调练习与反馈对技能发展不可替代的作用。SAT 的理论根基可以追溯到 Anderson 提出的认知学习模型（Adaptive Control of Thought-Rational, ACT-R），该模型描述了陈述性知识与程序性知识如何交互，并在大量练习和反馈调节下实现知识自动化，这为将语言学习纳入广义的技能习得视角提供了理论支撑²³。SAT 的基本框架可以概括为技能学习中的三种知识类型与技能掌握的三个发展阶段²⁴：

（1）陈述性阶段（Declarative Stage）：对应陈述性知识（know that），即关于事物和事实的信息储备；该阶段学习者通过显性学习掌握目标知识（例如形态句法规则、语音规则和词汇意义），最终做到“知道怎么描述”。

（2）程序性阶段（Procedural Stage）：对应程序性知识（know how），即将规则知

¹⁸ Eskenazi, M. (2009). An overview of spoken language technology for education. *Speech communication*, 51(10), 832-844.

¹⁹ Neri, A., Mich, O., Gerosa, M., & Giuliani, D. (2008). The effectiveness of computer assisted pronunciation training for foreign language learning by children. *Computer Assisted Language Learning*, 21(5), 393-408.

²⁰ 魏思,吴奎,竺博,等.语音评测技术助力英语口语教学与评价[J].人工智能,2019,(03):72-79.

²¹ DeKeyser, R. (2020). Skill acquisition theory. In *Theories in second language acquisition* (pp. 83-104). Routledge.

²² Taie, M. (2014). Skill acquisition theory and its important concepts in SLA. *Theory and practice in language studies*, 4(9), 1971.

²³ Anderson, J. R. (2013). *The adaptive character of thought*. Psychology Press.

²⁴ DeKeyser, R., & Criado, R. (2012). Automatization, skill acquisition, and practice in second language acquisition. *The encyclopedia of applied linguistics*, 323-331.

识用于解决问题的能力；该阶段学习者在大量练习和输入的驱动下，将显式知识转化为能够在实际交流中运用的程序性技能，最终“知道怎么做”。

（3）自动化阶段（Automatic Stage）：对应自动化知识，这是程序性知识经过重组与精细调整后的结果，其最终表现为技能的自动化与流利性，即学习者能够无需有意识注意即可准确、流畅地完成语言行为。

语音属于典型的程序性技能——不是静态的知识累积，而是一种需要不断练习和反馈调整的动作技能²⁵。在学习初期，学习者需要意识性地注意目标语言的音位规则与发音要点，此阶段反馈主要帮助学习者建立规则与意识化策略；在练习过程中，学习者通过反复模拟发音，根据反馈修正动作模式，将规则内化为可操作的技能；当学习者能够在无需意识调控的情况下自然发出语音时，即实现了技能的自动化²⁶。技能习得理论强调了反馈在技能学习中的重要作用，反馈能够帮助学习者识别当前表现与目标表现之间的差距，并指导学习者进行针对性的调整。这一点对于语音教学的过程来说尤为重要，因为学习者往往难以仅凭听觉输入发现自身发音错误，有研究表明，如果学习者在练习过程中缺乏及时反馈，其错误发音模式可能被固化甚至被不断强化，从而形成“语音化石化”（fossilization）现象，使发音难以进一步改进²⁷。

在传统课堂上，发音反馈主要依赖教师个体，但受制于课堂规模与教师精力，往往无法实现高频、即时和精细的反馈；自动语音评测系统能够实时分析学习者的发音行为，为学习者提供即时反馈，从而满足 SAT 所要求的高频反馈闭环。值得注意的是，反馈信息的粒度对于 SAT 也十分关键：Dlaska 与 Krekeler 通过实验研究发现，明确的个体纠错反馈能够显著提高学习者语音的可理解度，表明针对具体错误的反馈比单纯的听觉输入更有助于语音技能的发展²⁸。因此相较于仅是句级的“未通过/通过”标签，具体到词或音素层面的反馈能够为学习者提供明确的修正方向，使其在下一轮练习中进行有意识的调整，如指出“第 3 个词的/ŋ/ 发成了/n/”，可以明确指导学习者纠正具体语音动作，从而促进发音技能的程序性化与自动化发展。

2.2.2 形成性评价理论

形成性评价（Formative Assessment）概念最早由美国评估学者 Michael Scriven 提出，并在 Bloom、Hastings 和 Madaus 等学者的研究中得到系统发展。相关研究强调，评价应服务于教学过程本身，在学习过程中提供即时且具有指导意义的信息，以促进

²⁵ Celce-Murcia, M., Brinton, D., & Goodwin, J. M. (1996). *Teaching pronunciation: A reference for teachers of English to speakers of other languages*. Cambridge University Press.

²⁶ Anderson, J. R. (1982). Acquisition of cognitive skill. *Psychological review*, 89(4), 369.

²⁷ Ellis, R. (2006). Current issues in the teaching of grammar: An SLA perspective. *TESOL quarterly*, 40(1), 83-107.

²⁸ Dlaska, A., & Krekeler, C. (2013). The short-term effects of individual corrective feedback on L2 pronunciation. *System*, 41(1), 25-37.

学习者不断改进学习表现，而非仅用于学习结果的分类或选拔。²⁹

作为教育评价体系的重要组成部分，形成性评价的提出标志着教育评价理念从单纯的结果导向到过程导向的重要转变，理解形成性评价与终结性评价在目的上的差异，对于设计自动语音评测系统的反馈机制具有重要意义。

传统的终结性评价主要用于判断学习者是否达到某一既定标准，例如在语音学习中通过整体评分或等级评价来判断发音水平，然而这种整体性判定往往难以为学习者提供明确的改进方向。过度依赖终结性评价可能导致评价对学习本身的促进作用被削弱，学习者往往只关注分数和等级，而忽视学习过程中的反思与改进。相比之下，形成性评价强调评价活动与学习目标之间的一致性，其在学习活动过程中，通过频繁的反馈和诊断性评价揭示学习过程中的不足，使学习者能够获得具体的调整策略，该理论在教学与学习意义上强调评价作为改进工具的功能，即“评估促进学习”(assessment for learning)。³⁰

Sadler 在其经典论文 *Formative Assessment and the Design of Instructional Systems* 中提出，形成性评价本质上是一种反馈循环 (feedback loop)，其核心目的在于通过反馈促进学习者能力的发展，而不仅仅是对学习结果进行评价³¹。在 Sadler 的理论框架中，有效反馈需要满足三个条件：学习者能够理解高质量表现的标准、能够判断当前表现与标准之间的差距，并能够采取行动来缩小这一差距，这一观点揭示了形成性评价发挥学习促进作用的基本机制。

William 在后续的研究中进一步指出，反馈只有在能够被学习者用于调整学习行为时，才真正具有形成性评价的意义³²。换言之，有效的反馈不仅需要指出学习者存在的问题，还需要为学习者提供可操作的改进路径，比如在语音教学情境中，不应仅仅告知学习者发音是否正确，而应进一步明确指出具体错误所在，如音位偏差、重音位置或语调模式等，并为学习者提供可执行的纠音建议，帮助其在后续练习中进行针对性调整。有研究证明，相较于仅提供整体评分的评价方式，明确指出发音偏差并提供诊断性反馈更有助于学习者改善发音表现，比如提供针对音段特征(如元音和辅音)以及超音段特征(如重音、节奏和语调)的纠错反馈，能够显著促进学习者语音准确

²⁹ Stufflebeam, D. L. (1972). Benjamin S. Bloom, J. Thomas Hastinos, and George F. Madaus Handbook on Formative and Summative Evaluation of Student Learning. New York: McGraw-Hill Book Company, 1971. Pp. x+ 913 \$12.50. Psychometrika, 37(4), 487-489.

³⁰ Black, P., & Wiliam, D. (1998). Assessment and classroom learning. Assessment in Education: principles, policy & practice, 5(1), 7-74.

³¹ Sadler, D. R. (1989). Formative assessment and the design of instructional systems. Instructional science, 18(2), 119-144.

³² William, D. (2011). Formative assessment: Definitions and relationships. Studies in Educational Evaluation, 37(1), 3-14.

性的提升，从而提升整体语音可理解度。³³

2.2.3 Hattie & Timperley 的反馈模型

反馈（feedback）在教育和学习领域被广泛认为是影响学习效果的重要因素之一，具有显著的促进学习成效的潜力。真正具有促进作用的反馈应能够帮助学习者建立目标意识、理解当前表现相对于目标的位置，并明确下一步应采取何种策略或行动。³⁴

Hattie 与 Timperley 在其经典文章 *The Power of Feedback* 中提出了系统化的反馈层级模型（Model of Feedback to Enhance Learning），以进一步解释反馈如何影响学习过程，该模型围绕学习者在学习情境中需要回答的三个核心问题展开：“Where am I going?”（学习目标与标准是什么？）、“How am I going?”（当前表现如何？有哪些不足？）以及“Where to next?”（下一步需要做什么改进？）。这三个问题分别对应于对学习目标、当前表现状态与未来改进路线的反馈方向，是评价何种反馈更有利于促进深度学习的关键视角。该研究强调有效反馈必须提供具体、可操作的信息，而非简单评价，并将反馈按照其关注的信息深度划分为三个层次：结果层（Outcome/Task level）、过程层（Process level）、自我调节层（Self-regulation level）。任务层反馈主要指出任务完成情况，例如错误位置；过程层反馈解释错误产生的原因并提供策略建议；自我调节层反馈则帮助学习者反思学习策略并提升自主学习能力。举例来讲，对学习者的某次跟读练习仅提供“发音 80 分”的反馈只能回答“How am I going?”，这种仅提供结果层信息的反馈虽然具有一定评价作用，但对技能性学习（如发音）而言，推动学习进步的作用有限；而若反馈能深入任务层或过程层，指出具体错误、解释错误形成的方式并指导下一步练习策略，则更有利于学习者调整实践行为与认知策略，从而实现技能提升目标。

后续研究通过对大量实证研究进行整合分析，进一步验证了反馈在学习中的重要作用。例如，Wisniewski 等人对 435 项教育研究进行元分析发现，反馈对学习表现具有显著促进作用，其平均效应量约为 0.48，这一结果表明了反馈是影响学习效果的重要因素之一³⁵。对于自动语音评测系统而言，若仅提供整体评分，学习者往往难以判断错误发生在何处，也无法明确下一步应如何调整发音策略，因此本研究将反馈粒度由句级打分细化至词级诊断，将语音评测反馈由结果层推进至任务层，并尝试向过程层延伸，以提高反馈的学习价值，支持学习者进行有意识的调整与改进。

³³ Saito, K., & Lyster, R. (2012). Effects of form - focused instruction and corrective feedback on L2 pronunciation development of /ɪ/ by Japanese learners of English. *Language learning*, 62(2), 595-633.

³⁴ Hattie, J., & Timperley, H. (2007). The power of feedback. *Review of Educational Research*, 77(1), 81-112.

³⁵ Wisniewski, B., Zierer, K., & Hattie, J. (2020). The power of feedback revisited: A meta-analysis of educational feedback research. *Frontiers in psychology*, 10, 487662.

2.2.4 元认知调节

“元认知”（metacognition）概念最早由美国心理学家 Flavell 提出，他将元认知定义为个体对自身认知过程的知识以及对这些过程进行监控和调节的能力，即“对认知的认知”（thinking about thinking），并指出元认知不仅包括对认知活动的意识，还包括对认知活动的调控能力³⁶。在 Flavell 的模型中，元认知主要由两部分构成：元认知知识（metacognitive knowledge）与元认知调节（metacognitive regulation）。其中，元认知知识包括学习者对自身能力、任务特点和学习策略的认识；而元认知调节则包含计划（planning）、监控（monitoring）与评估（evaluation）等三个核心过程，这些过程构成了学习者进行自主学习的重要机制。在学习过程中，学习者能够持续的元认知监控来不断评估自身理解或表现状态，并根据需要调整学习策略，比如当发现自己未能达到预期目标时，可以通过改变学习方法或增加练习来改进表现，这一过程构成学习调节的重要机制。这一理论的核心意义在于：学习并不仅仅是信息加工过程，还包括对学习过程本身的监控与调节。

进入 1990 年代以后，元认知逐渐与自我调节学习（Self-Regulated Learning, SRL）理论³⁷结合，前者是学习者实现自主学习的重要机制，后者强调学习者能够主动设定学习目标、监控学习进展并调整学习策略，而这些行为本质上依赖于元认知能力。在这一理论框架下，学习者不再被视为被动接受知识的对象，而是通过元认知调节主动参与学习过程，在这一过程中的反馈不仅是评价学习表现的工具，更是触发学习者元认知调节的重要机制，当学习者获得明确反馈时，他们能够识别当前表现与目标之间的差距，并据此调整学习策略。

本节从技能习得理论、形成性评价理论、反馈模型以及元认知调节机制四个方面构建了语音教学与自动评测研究的理论基础。从技能习得理论的视角来看，语音本质上是一种程序性动作技能，其发展高度依赖于大量的反复练习与及时、精细的反馈；为了有效促进这一转化，评价体系必须超越传统的终结性打分，转向强调过程与发展的形成性评价；Hattie 和 Timperley 的反馈模型进一步揭示了有效反馈的层级结构，指出反馈必须提供深入至任务层和过程层的具体诊断信息；当这些高质量的反馈被学习者接收时，便能有效触发其元认知调节机制，促使他们主动监控学习过程并调整发音策略。

³⁶ Flavell, J. H. (1979). Metacognition and cognitive monitoring: A new area of cognitive-developmental inquiry. *American psychologist*, 34(10), 906.

³⁷ Zhang, D., & Zhang, L. J. (2019). Metacognition and self-regulated learning (SRL) in second/foreign language teaching. In *Second handbook of English language teaching* (pp. 883-897). Cham: Springer International Publishing.

在传统的语音课堂教学中，往往难以满足每位学习者对高频个性化练习与即时纠错反馈的需求，而自动语音评测系统的引入恰好弥补了这一现实局限³⁸。随着评测技术的发展，反馈粒度的细化（如从句级到词级甚至音素级）推动了语音教学进一步走向“高频练习-深度反馈-元认知调节”闭环，实现以技术赋能语音技能的自动化与自主化发展。

2.3 自动语音评测技术路径

2.3.1 基于特征比较的传统语音评测

自动语音评测早期较为系统的一类技术路径是基于特征比较（feature comparison）的传统方法。该方法将学习者语音与标准示范语音视为两条可比较的声学序列，在预处理后分别提取若干能够表征发音质量的声学特征，如梅尔频率倒谱系数（MFCC）、基频、时长、能量以及共振峰等，再利用模板匹配或动态时间规整（DTW）等方法对两段语音进行时序对齐，最后根据对齐后的局部距离或整体相似度输出发音分数。

Franco 等人较早提出将自动评分用于语言教学场景，强调通过声学匹配对学习者的发音质量进行量化评估³⁹；随后，Ronen、Neumeyer 与 Franco 进一步将这一思路用于误读检测，试图在整体评分之外识别特定发音问题⁴⁰；Neumeyer 等人则在此基础上把分段特征与超音段信息结合起来，系统考察了自动评分与人工评分之间的一致性，推动了传统语音评测从“粗略匹配”向“多特征综合比较”的发展⁴¹。这一时期的研究方法本质上都基于一个共同的假设，即“标准发音与学习者发音之间的偏差可以通过可计算的声学距离来表征”，因此算法设计重点在于所选特征是否足够鲁棒，以及对齐策略能否有效消解语速差异、停顿位置差异等非目标因素的干扰。

基于特征比较的传统语音评测直接依赖“学习者语音—标准语音”的对应比较关系，不必依赖大规模带标注训练语料，因而在语音资源有限、文本与标准音频已知的朗读练习场景中具有较高可操作性，构成了早期 CAPT 系统中的技术基础^{42,43}。然而，

³⁸ Rogerson-Revell, P. M. (2021). Computer-assisted pronunciation training (CAPT): Current issues and future directions. *Relc Journal*, 52(1), 189-205.

³⁹ Franco, H., Neumeyer, L., Kim, Y., & Ronen, O. (1997, April). Automatic pronunciation scoring for language instruction. In *1997 IEEE international conference on acoustics, speech, and signal processing* (Vol. 2, pp. 1471-1474). IEEE.

⁴⁰ Ronen, O., Neumeyer, L., & Franco, H. (1997). Automatic detection of mispronunciation for language instruction. In *Proc. Eurospeech 1997* (pp. 649-652).

⁴¹ Neumeyer, L., Franco, H., Digalakis, V., & Weintraub, M. (2000). Automatic scoring of pronunciation quality. *Speech communication*, 30(2-3), 83-93.

⁴² Strik, H., Neri, A., & Cucchiari, C. (2008). Speech technology for language tutoring.

⁴³ Eskenazi, M. (2009). An overview of spoken language technology for education. *Speech communication*, 51(10), 832-844.

该方法通常以整体相似度为核心,虽然可以给出句子、词语甚至片段级评分,但对“错误究竟发生在哪个音段、属于何种误读类型”的解释能力较弱,难以支持真正意义上的细粒度反馈。

2.3.2 基于声学模型的音素级语音评测

与基于整体声学特征比较的评测方法相比,基于声学模型的音素级语音评测进一步利用了已知文本信息,先借助发音词典和声学模型将学习者语音与目标文本进行强制对齐,再根据各音素在对齐过程中的似然分数、后验概率或相邻竞争音素之间的差异来判断该音素的发音质量,将语音评测从“整体相似度判断”推进到“音素级评分与错误定位”阶段。这一技术路径最具代表性的奠基性研究是 Witt 与 Young 提出的 Goodness of Pronunciation (GOP) 评分方法,该方法利用已知文本对学习者的语音进行音素级别的强制对齐 (force alignment),再比较目标音素与其他竞争音素在给定语音观测下的后验概率差异,将得到的对数似然比 (log-likelihood ratio) 作为该音素的发音评分,最后设定阈值; GOP 值越大,表示发音越接近标准,低于阈值则判定为潜在发音错误,从而实现了音素级的发音评分⁴⁴。GOP 方法的关键突破在于它把“文本先验”与“音素级建模”真正纳入了评测过程,因此被普遍视为自动发音评测从整体评分走向细粒度诊断的重要转折点。

值得注意的是, GOP 是一种基于统计的方法,其模型是在目标语言的 L1 数据集上(即标准发音)训练得到的,虽然不需要错误标注,但此类方法只能提供目标文本所对应的分数,给出一个整体的发音评分,但对误读“具体是什么”的诊断能力仍然有限。基于这一认识, Harrison 等人提出 Extended Recognition Network (ERN),在构建单词 HMM 状态时显式引入学习者可能出现的错误发音模式,使系统不仅能够判断某个音素是否发错,还能在一定程度上推测错误类型,从而推动音素级评测从单纯的发音评分走向发音诊断⁴⁵;然而,该算法往往依赖预定义的误读规则或错误模式,在遇到未在训练中出现的误读时会导致性能下降。Franco 等人通过显式区分“正确发音模型”与“误读发音模型”的方式进行误读检测,说明当研究目标从“给分”转向“指出哪里错、怎么错”时,单一的 L1 语音建模往往已经不够,需要为非母语学习者的实际发音建立更细致的建模框架。⁴⁶

⁴⁴ Witt, S. M., & Young, S. J. (2000). Phone-level pronunciation scoring and assessment for interactive language learning. *Speech communication*, 30(2-3), 95-108.

⁴⁵ Harrison, A. M., Lo, W. K., Qian, X., & Meng, H. (2009, September). Implementation of an extended recognition network for mispronunciation detection and diagnosis in computer-assisted pronunciation training. In *SLaTE* (pp. 45-48).

⁴⁶ Franco, H., Ferrer, L., & Bratt, H. (2014, May). Adaptive and discriminative modeling for improved mispronunciation detection. In *2014 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 7709-7713). IEEE.

Helen Meng 教授团队进一步指出了传统 HMM/GMM 框架在 L2 发音场景中的局限,即仅用母语者标准发音训练得到的单一声学模型往往难以充分刻画学习者的复杂发音模式,并提出了 Multidistribution DNN (Deep Neural Networks),通过同时建模标准发音与非标准发音的分布特征,提升了误读检测与诊断的性能,将传统声学模型思路推进到更强的 acoustic-phonemic 建模⁴⁷。两年后,该团队在此研究的基础上采用了多任务学习技术 (Multitask Learning) 来改进 acoustic-phonemic model,通过共享检测与诊断相关任务的信息来增强模型对错误发音模式的区分能力;同年,他们基于无监督聚类的方法,提出了英语 L2 语音中的扩展音素集 (Extended Phoneme Set in L2 speech, L2-EPS),以更全面地描述 L2 发音模式,用更细化的音素类别刻画学习者语音练习中出现的非典型发音现象。^{48,49}

基于声学模型的音素级语音评测方法利用了先验文本信息,强调局部音段评分与错误定位,而不是仅输出整体句级分数,推动了文本已知的朗读场景的评测实现从“粗粒度整体评价”到“细粒度诊断”的关键转折,更加契合语言学习中的形成性反馈需求。

2.3.3 基于深度学习的端到端语音评测

随着深度学习在语音识别领域的快速发展,自动语音评测也逐渐转向以神经网络为核心的端到端方法。与传统评测方法相比,端到端方法通过深度学习模型直接学习“输入语音-评测结果”之间的映射关系,通过统一模型整合声学特征提取、时序建模和错误判定过程,一定程度上摆脱了传统方法对繁琐的专家规则设计的依赖,使研究重心从手工特征工程转向了模型设计,通过优化模型架构和训练方式来达到更好的效果,且具有更好的迁移性和鲁棒性。⁵⁰

Leung 等人提出了基于 CNN-RNN-CTC 网络的端到端发音错误检测与诊断 (MDD) 模型,该方法将卷积神经网络、循环神经网络与 CTC 损失结合起来,直接对学习者的语音进行音素序列建模,并据此实现误读检测与诊断,证明端到端语音识别框架可以

⁴⁷ Li, K., Qian, X., & Meng, H. (2016). Mispronunciation detection and diagnosis in l2 english speech using multidistribution deep neural networks. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 25(1), 193-207.

⁴⁸ Mao, S., Wu, Z., Li, R., Li, X., Meng, H., & Cai, L. (2018, April). Applying multitask learning to acoustic-phonemic model for mispronunciation detection and diagnosis in L2 English speech. In *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 6254-6258). IEEE.

⁴⁹ Mao, S., Li, X., Li, K., Wu, Z., Liu, X., & Meng, H. (2018, April). Unsupervised discovery of an extended phoneme set in l2 english speech for mispronunciation detection and diagnosis. In *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 6244-6248). IEEE.

⁵⁰ El Kheir, Y., Ali, A., & Chowdhury, S. A. (2023). Automatic pronunciation assessment-a review. *Findings of the Association for Computational Linguistics: EMNLP 2023*, 8304-8324.

被较自然地迁移到发音评测任务中⁵¹。在此基础上，Feng 等人提出 SED-MDD 方法，通过在模型中引入参考文本编码，将学习者语音与目标文本共同纳入端到端建模过程，验证了端到端方法并不必然排斥文本先验，而是可以通过条件输入的方式将其融合到统一模型之中。⁵²

在模型架构层面，端到端语音评测迎来了 Transformer 和自监督预训练框架的引进。Wu 等人使用 Transformer 架构替代了传统 CNN-RNN 组合，显示出更强的序列建模与表示学习能力⁵³。在此之后，Kim 等人进一步系统考察了自监督语音表示学习（self-supervised speech representation learning）在自动发音评测中的应用，说明基于大规模语音预训练得到的表示能够显著增强模型对发音质量差异的刻画能力，也推动了自动发音评测从“端到端结构设计”进一步走向“预训练表示+下游评测任务微调”的新阶段。⁵⁴

端到端语音评测方法代表了当前自动发音评测的主流发展方向，一方面得益于深度神经网络带来的更强大的非线性建模能力，更好地学习了复杂的 L2 发音偏差模式；另一方面也在于它能够通过统一框架整合识别、对齐、评分或诊断等多个环节，从而在高资源语种与公开数据集上不断刷新评测性能⁵⁵。然而，其效果往往建立在较充足的数据资源、较高质量的标注和较强的计算支持之上，因此在低资源语种、尤其是缺乏大规模带标注学习者语音数据的场景下，直接迁移和稳定部署仍然面临较大困难。

56

自动语音评测技术大致经历了从“基于特征比较的传统方法”到“基于声学模型的音素级评测”，再到“基于深度学习的端到端建模”的发展过程。早期方法主要通过声学特征提取与模板匹配来衡量学习者语音与标准语音之间的相似度，虽然实现简单，但难以提供细粒度的错误定位；随着声学模型和强制对齐技术的发展，研究者能

⁵¹ Leung, W. K., Liu, X., & Meng, H. (2019, May). CNN-RNN-CTC based end-to-end mispronunciation detection and diagnosis. In *ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 8132-8136). IEEE.

⁵² Feng, Y., Fu, G., Chen, Q., & Chen, K. (2020, May). SED-MDD: Towards sentence dependent end-to-end mispronunciation detection and diagnosis. In *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 3492-3496). IEEE.

⁵³ Wu, M., Li, K., Leung, W. K., & Meng, H. (2021, August). Transformer Based End-to-End Mispronunciation Detection and Diagnosis. In *Interspeech* (pp. 3954-3958).

⁵⁴ Kim, E., Jeon, J. J., Seo, H., & Kim, H. (2022). Automatic pronunciation assessment using self-supervised speech representation learning. *arXiv preprint arXiv:2204.03863*.

⁵⁵ El Kheir, Y., Ali, A., & Chowdhury, S. A. (2023). Automatic pronunciation assessment-a review. *Findings of the Association for Computational Linguistics: EMNLP 2023*, 8304-8324.

⁵⁶ Yan, B. C., & Chen, B. (2021, August). End-to-end mispronunciation detection and diagnosis from raw waveforms. In *2021 29th European Signal Processing Conference (EUSIPCO)* (pp. 61-65). IEEE.

够利用文本先验将连续语音映射到音素序列，并在音素层面进行评分与误读检测，从而实现更具解释性的发音诊断；近年来，深度学习端到端模型进一步通过统一框架整合语音表示学习与评测决策过程，在高资源语种场景中显著提升了自动发音评测性能。

然而，这些方法在实现细粒度反馈能力与对数据资源依赖之间仍存在权衡，特别是在低资源语种场景中，如何在有限语音数据条件下实现稳定、可解释的发音评测反馈，仍然是当前研究需要关注的重要问题。

2.4 低资源语种语音评测研究现状

自动发音评测作为 CAPT 的核心组成部分，近年来在深度学习和语音表示学习推动下取得了明显进展，但现有研究仍面临资源可得性、模型泛化能力和反馈可解释性等方面的挑战⁵⁷；与此同时，当前实证研究对象仍主要集中于英语学习者，训练任务多以听后跟读和朗读练习为主，研究覆盖的语言类型与教学情境相对有限。⁵⁸因此，对于低资源语种而言，自动语音评测并非简单地将既有高资源语言模型迁移即可解决，而需要结合具体语言资源条件与教学反馈需求重新设计评测路径。

相比英语等高资源语言，针对低资源语种的自动语音评测研究仍然较为有限，其核心瓶颈在于标注数据稀缺与语言特异性导致的模型迁移困难。近年来，一些研究开始探索面向低资源语言的自动语音评测方法，但已有的研究仅覆盖了少数低资源语言或语言变体，如阿拉伯语、芬兰瑞典语（Finland Swedish，瑞典语在芬兰的一种独特变体）、孟加拉语等^{59,60,61}，而针对太平洋地区语言（如斐济语）的自动语音评测研究仍较为匮乏。对于斐济语而言，目前已有的语音研究主要集中在语言学层面的语音与音系描述或发音习得，而面向斐济语语音学习的自动语音评测研究仍较为有限。

62,63

⁵⁷ El Kheir, Y., Ali, A., & Chowdhury, S. A. (2023). Automatic pronunciation assessment-a review. *Findings of the Association for Computational Linguistics: EMNLP 2023*, 8304-8324.

⁵⁸ Amrate, M., & Tsai, P. H. (2025). Computer-assisted pronunciation training: A systematic review. *ReCALL*, 37(1), 22-42.

⁵⁹ Alrashoudi, N., Al-Khalifa, H., & Alotaibi, Y. (2025). Improving mispronunciation detection and diagnosis for non-native learners of the Arabic language. *Discover Computing*, 28(1), 1.

⁶⁰ Phan, N., Kuronen, M., Kautonen, M., Ullakonoja, R., von Zansen, A., Getman, Y., ... & Kurimo, M. (2025). Mispronunciation Detection Without L2 Pronunciation Dataset in Low-Resource Setting: A Case Study in Finland Swedish. *arXiv preprint arXiv:2506.01156*.

⁶¹ Bharati, P., Chandra, S., Aitawade, A., Pramanik, D., Gaddamedi, S. P., & Mandal, S. K. D. (2026). A deep neural network-based automatic mispronunciation detection in Bengali accented English speech. *Discover Computing*, 29(1), 71.

⁶² Scott, N. C. (1948). A study in the phonetics of Fijian. *Bulletin of SOAS*, 12(3-4), 737-752.

⁶³ Hopf, S. C., McLeod, S., & Geraghty, P. (2016). A contrastive analysis of the phonologies of two Fiji English dialects: A diagnostic guide for speech – language pathologists. *Speech, Language and Hearing*, 19(2), 96-104.

按照技术路径来划分,可将现有低资源语种语音评测研究方法大致分为三类:第一类是跨语言迁移方法,即利用高资源语言训练的语音模型,通过迁移学习或多语言预训练模型适配低资源语言,以缓解训练数据不足的问题,然而,由于不同语言在音系结构、音位系统和语音实现方式方面存在差异,直接迁移高资源语言模型往往会影响评测准确性;第二类是基于规则或音系知识的评测方法,通常通过人工构建音系规则或利用发音词典,对学习者语音与标准语音之间的差异进行分析;第三类是基于深度学习的语音评测方法,如通过多任务学习或数据增强方法,提高模型在低资源环境下的性能,然而该类方法仍然依赖一定规模的语音数据和标注资源,而数据稀缺问题仍然是低资源语言语音技术发展的主要瓶颈⁶⁴。从教育应用的角度来看,现有研究大多集中在语音识别算法或错误检测模型的性能提升上,而较少从语言教学需求出发探讨语音评测反馈的教学价值,比如评测结果如何转化为对学习者具有指导意义的教学反馈,这种技术导向的研究路径在一定程度上限制了语音评测系统在实际教学中的应用效果。

本文对多种主流语言学习平台进行了比较,从表 2.1 可以看出,目前已有部分数字平台开始尝试支持非通用语种或低资源语种的学习,但能够同时支持低资源语种并提供语音评测功能的平台仍然较为有限。例如, uTalk 与 Mango Languages 等平台提供覆盖数十至上百种语言的学习资源,其中包括斐济语、苏格兰盖尔语等较少教授的语言; Mondly、Memrise 等应用通过扩展语种或社区课程机制,使学习者能够接触到更多小语种; Speak Pacific 提供了 7 种包括斐济语在内的太平洋岛屿语言的入门级学习资源。然而,这些平台大多以词汇学习或简单听说练习为主,较少提供细粒度的发音评测反馈;而具备自动语音评测能力的平台(如 Duolingo、Mondly)则主要面向高资源语言。相比之下,北外多语智慧学习平台专门面向低资源语种教学场景,已支持斐济语、塔玛齐格特语等 12 个语种,并在课程中嵌入语音评测模块,基于“特征提取+音频对齐+差分计算”的传统语音评测方法,为学习者提供发音练习与句子级别的发音打分。

总体而言,低资源语种自动语音评测研究仍处于探索阶段。一方面,现有研究仅覆盖了少数语言或语言变体,研究对象较为有限;另一方面,现有技术路径在数据需求、跨语言适配和教学反馈设计方面仍然存在一定局限。因此,在低资源语种语音学习场景中,如何在有限语料条件下构建可用且具有教学价值的语音评测系统,仍然是一个值得进一步研究的重要问题。

⁶⁴ Slam, W., Li, Y., & Urouvas, N. (2023). Frontier research on low-resource speech recognition technology. *Sensors*, 23(22), 9096.

表 2.1 常见外语学习平台

名称	包含低资源语种	支持发音评测	网站
北外多语智慧学习平台	√	√	App, 无网站
Speak Pacific	√	×	App, 无网站
uTalk	√	×	https://utalk.com
Mango Languages	√	×	https://mangolanguages.com/
50Languages	√	×	https://www.50languages.com/
Mondly	少量	√	https://www.mondly.com/
Memrise	√	√	https://www.memrise.com/
Duolingo	少量	√	https://www.duolingo.com/
Rosetta Stone	少量	√	https://www.rosettastone.com/
Babbel	×	√	http://babbel.com/

2.5 研究评述

自动语音评测技术在英语、汉语等高资源语种的教学场景中已形成较为成熟的技术体系与应用模式,且技能习得理论、形成性评价理论等为语音评测的反馈设计提供了坚实的理论支撑,但针对低资源语种的自动语音评测研究仍处于探索阶段,在研究覆盖范围、技术适配性、教学反馈融合等方面存在显著研究空白,难以满足低资源语种语音教学的实际需求。当前研究与实践主要存在以下三方面不足:

- (1) 针对低资源语种的语音评测研究严重不足。现有自动语音评测研究仍高度集中于英语、汉语、西班牙语等国际通用的高资源语种,针对低资源语种的研究仅零散覆盖阿拉伯语、孟加拉语、芬兰瑞典语等少数语言;对于斐济语,现有研究仅停留在语言学层面的音系、语音描述,针对该语种的自动语音评测技术与教学应用探索几乎空白。当前主流的语音评测技术(尤其是基于深度学习的端到端方法)高度依赖大规模、高质量的母语者发音数据库和学习者发音错误标注语料,难以直接迁移至低资源语种。
- (2) 评测粒度不足,难以提供有效教学反馈。现有低资源语种相关的语音评测实践,及多数跨语种语音评测平台的功能设计,仍以句子级整体评分为主,仅能向学习者提供“通过/未通过”或整体分数的粗粒度反馈,无法实现单词级、音素级的错误定位与诊断;而即使是高资源语种中已实现的音素级评测技术,也因低资源

语种的语料限制难以直接迁移应用，使得语音教学难以实现“精准纠错-针对性练习-技能提升”的闭环。

- (3) 技术导向明显，缺乏与教学理论融合的反馈设计。当前针对低资源语种的语音评测研究多为技术导向，聚焦于声学模型优化、错误检测准确率提高等技术指标，忽视了教学理论的支撑与评测结果的教学转化。若评测系统只能输出整句评分或二元评估结果，则难以发挥形成性评价的作用，支持学习者在自主学习的过程中进行自我纠错。

本研究以某高校多语智慧学习平台斐济语模块为具体研究场景，探究如何构建更具诊断能力的自动语音评测系统，以支持低资源语种语音教学的反馈环节。为解决上述问题，本研究提出一种面向低资源语种朗读评测场景的细粒度语音评测框架，充分利用先验文本信息，通过在传统特征匹配方法中引入文本语音强制对齐技术，实现词级与音素级的发音诊断；同时结合语音教学理论，将评测结果转化为具有指导意义的形成性教学反馈，从而赋能学习者在学习过程中形成“评测-反馈-修正-再练习”的闭环，促进学习者进行有意识的针对性自我纠错，实现“以评促学”的教学目标。

第3章 研究设计

3.1 研究思路

本研究遵循开发研究法（Development Research）的基本范式，以解决低资源语种语音教学中评测反馈粒度不足、针对性指导匮乏的现实问题为核心目标，构建了如图 3.1 所示的研究逻辑框架，整个研究工作分为以下四个阶段展开：

第一阶段：问题分析与资源构建。本阶段立足于低资源语种语音教学的现实困境，通过对现有自动语音评测路径的适配性分析，明确研究目标与技术路线，并在此基础上构建支持斐济语评测任务的基础资源体系，通过整合标准朗读语音、对应文本及发音词典，沉淀多模态平行语料库，为后续算法实现奠定数据基础。

第二阶段：语音评测方法设计。斐济语属于低资源语种，针对其缺乏发音偏误标注语料的现实约束，本阶段设计并构建了基于 MFA-GFCC-DTW 的细粒度语音评测路径：通过 Montreal Forced Aligner (MFA)实现音素级的时间边界对齐，提取抗噪性能优越的 GFCC 声学特征，并利用动态时间规整（DTW）算法计算学习者语音与标准语音的相似度，从而实现从句级、词级到音素级的多层次发音质量度量。

第三阶段：教学反馈设计与系统开发。为弥合底层声学特征指标与上层教学指导信息之间的鸿沟，本阶段重点设计了细粒度反馈生成机制，利用大语言模型（LLM）的语言生成能力，将多层级的结构化评测结果转化为具有教学解释性的自然语言反馈；并且以上述功能为核心，开发斐济语语音评测原型系统，实现技术方案向数字化学习工具的转化。

第四阶段：教学应用验证与结果分析。将原型系统嵌入北外多语智慧学习平台的真实教学情境中，组织学习者进行试用体验，并通过问卷调查方式收集多维数据，定量分析系统的可用性与教学支持效果，定性挖掘学习者的使用感知与改进建议，以此验证 MFA-GFCC-DTW 路径在低资源语种语音教学中的应用价值与理论意义。




图 3.1 本文的研究流程图

3.2 研究方法

本研究采用开发研究法（Development Research）作为整体研究方法，设计并开发斐济语语音评测系统，实现词级、音素级细粒度诊断反馈，在真实教学情境中进行应用验证；为确保研究结果的科学性与全面性，研究同时采用了问卷调查法获取学习者对系统可用性的定量评价，其中包含开放问答题以深度挖掘学习者的主观感知与改进建议，以量化与质性相结合的数据互证方式全方位评估 MFA-GFCC-DTW 路径在真实教学情境中的有效性。

3.2.1 开发研究法

开发研究法是教育技术学中兼具理论建构与实践改良属性的核心方法，侧重于教育产品或教学系统的设计、开发与评价过程⁶⁵。Richey 与 Klein 根据研究目的不同，

⁶⁵ Van den Akker, J. (1999). Principles and methods of development research. In *Design approaches and tools in education and training* (pp. 1-14). Dordrecht: Springer Netherlands.

将开发研究法分为两种主要类型：一类是“过程指向型”，即以具体产品开发解决特定问题；另一类是“模型指向型”，即通过对多个开发案例进行分析，提炼普适性设计原则。⁶⁶

本研究属于典型的“过程指向型”开发研究，包含了开发研究法所必须的问题分析、方案设计、产品开发以及应用验证等阶段，具体而言，首先针对低资源语种语音评测技术的发展现状及其在斐济语教学中的应用需求进行分析；接下来设计并实现面向斐济语语音学习的自动语音评测方法与细粒度反馈机制，并开发语音评测原型系统；最后在真实学习情境中组织学习者进行系统试用，通过问卷调查收集学习者反馈，对系统的可用性和反馈效果进行初步评估。该研究过程既涉及技术系统的设计与实现，又在真实学习情境中对系统的应用效果进行评估，验证了该技术路径对于提升低资源语种学习者发音质量的实际价值。

3.2.2 问卷调查法

问卷调查法（Questionnaire Survey）是一种典型的定量研究方法，能够通过结构化问卷收集较多研究对象的意见、态度或体验数据，并通过统计分析揭示群体在特定问题上的整体特征，相比访谈等质性方法，问卷调查具有结构清晰、数据处理效率高以及结果可量化等特点，因此在教育研究与社会科学中被广泛应用⁶⁷。在计算机辅助语言学习（CALL）领域，问卷调查常被用于评估学习者对学习系统的使用体验、学习满意度以及对教学工具的评价。

在本研究中，问卷调查法主要用于收集学习者在使用语音评测系统后的体验评价，以评估系统在语音学习中的教学支持效果。问卷题项主要采用 Likert 五点量表形式，从学习者角度评价系统反馈的清晰度、可理解性以及对话音学习的帮助程度等方面，例如，学习者是否能够通过系统反馈更清楚地识别发音错误、系统反馈是否易于理解以及系统是否有助于学习者进行针对性发音练习等。通过对问卷数据进行统计分析，可以从整体上了解学习者对系统反馈效果和使用体验的评价，从而为后续系统优化提供依据。

3.3 研究情境与研究对象

3.3.1 研究情境

本研究依托某高校自主研发的多语智慧学习平台开展。该平台面向非通用语种教

⁶⁶ Richey, R. C., & Klein, J. D. (2014). *Design and development research: Methods, strategies, and issues*. Routledge.

⁶⁷ Creswell, J. W., & Creswell, J. D. (2017). *Research design: Qualitative, quantitative, and mixed methods approaches*. Sage publications.

学需求开发，为斐济语、塔玛齐格特语、马其顿语等 12 个低资源语种提供数字化学习环境，支持课程学习、在线练习以及学习过程数据记录等功能，通过数字化资源与在线学习活动扩展学习机会，为学习者提供了更加灵活的学习方式，并在一定程度上缓解了小语种教学资源不足的问题。⁶⁸

在该平台中，斐济语课程为学习者提供词句学习、语音练习、情景对话练习等学习内容。当前平台中的语音练习主要包括单词跟读和句子跟读两类任务，学习者通过平台提供的标准语音示范进行模仿练习，并录制自己的朗读音，频以完成语音练习任务，系统会对学习者录制的语音进行自动评测，并给出发音结果反馈。然而，现有的评测反馈粒度较粗糙，仅以“通过（Successful）”或“未通过（Failed）”的二元状态呈现（如图 3.2），属于典型的结果性评价，系统无法揭示发音偏误的具体位置（词级或音素级），亦无法提供偏误性质的解释。因此学习者只能获知自己的发音是否达到系统要求，却难以明确具体的错误位置或发音偏差原因，比如问题发生在单词还是音素层面，从而容易陷入“无效重复练习”的困境，难以触发有效的自我纠错机制。

基于此，本研究聚焦于该平台斐济语课程的语音跟读练习场景，通过植入支持词级与音素级错误定位的评测模块，将原有的“二元结果反馈”升级为“细粒度诊断反馈”，以此探索提升低资源语种语音教学效能的技术路径。



图 3.2 斐济语课程中成功跟读并通过语音评测（Successful）的页面动画

3.3.2 研究对象

本研究的研究对象为某高校使用多语智慧学习平台学习斐济语课程的学习者。研究共邀 6 名学习者参与系统试用，其母语均为汉语，其中既包括语言类专业学生，也

⁶⁸ Kvale, S., & Brinkmann, S. (2009). *Interviews: Learning the craft of qualitative research interviewing*. sage.

包括非语言类专业学生，参与者均已完成一定阶段的斐济语基础学习，并能够进行简单的单词和句子朗读练习，因此具备参与语音评测系统试用的基本条件。

此外，本研究在语音评测系统开发过程中使用了斐济语母语者标准语音语料以及学习者跟读语音数据，这些语音数据主要用于语音评测模型构建与系统功能实现，为系统的评测算法提供了必要的数据库基础。

3.4 研究流程

3.4.1 斐济语语音评测资源构建

在自动语音评测系统的开发过程中，语音资源是实现语音特征分析与发音评估的重要基础。本研究首先构建斐济语语音评测所需的基础资源，包括标准语音语料、文本数据以及发音词典等，以支持后续语音评测方法设计与系统开发。

本研究整理并使用了斐济语母语者朗读语音数据，语料共包含 2781 条标准朗读音频，涵盖了由斐济语母语者录制的、覆盖日常交际情境的标准语音，并配套提供对应的斐济语转录文本，可为语音评测提供标准发音参考；同时基于此构建了斐济语发音词典，将词汇单元映射至其对应的音素序列，为实现语音信号与文本信息之间的高精度自动对齐提供了规则基础。在上述工作的基础上，利用 Montreal Forced Aligner (MFA) 工具对标准语音与文本进行强制对齐，实现对语音信号的词级与音素级切分，为后续语音评测中的细粒度发音分析提供必要的数据库基础。

通过上述语音资源构建过程，本研究为斐济语语音评测方法设计与系统实现奠定了数据基础，使系统能够在标准语音参考的基础上对学习者的发音进行自动分析与评估。

3.4.2 语音评测方法设计

在完成斐济语语音评测资源构建的基础上，本研究进一步设计适用于低资源语种的语音评测方法，提出了 MFA-GFCC-DTW 混合式评测路径，该路径的核心设计思想是将发音质量的优劣解构为学习者语音与母语者标准语音在声学特征层面的可量化距离，通过语音-文本对齐、声学特征提取、相似度计算等步骤，在不依赖大规模标注语料的情况下实现对学习者发音质量的自动评估。

首先，通过 Montreal Forced Aligner (MFA) 工具对学习者的发音与参考文本进行强制对齐，从而精准定位其语音流中每个词乃至每个音素的起止时间边界，为实现词级甚至音素级错误诊断提供基础；接着在已定位的各个语音片段上，提取在噪声环境中具有优越鲁棒性的 Gammatone 频率倒谱系数 (GFCC) 作为声学特征，确保评测结果在真实教学场景中的稳定性；最后采用动态时间规整 (DTW) 算法，在词级和音

素级上分别计算学习者与标准发音的 GFCC 特征序列之间的最小累积距离,以此反映二者在发音上的差异程度,从而构成了本研究多层次、细粒度语音评测体系的算法基石。

通过上述方法,本研究构建了基于 MFA-GFCC-DTW 的语音评测技术路径,为后续语音评测系统开发以及细粒度发音反馈生成提供方法基础,具体实现细节与参数配置将在第四章中展开详述。

3.4.3 语音评测原型系统开发

在确立评测方法之后,研究的第三阶段致力于探索该算法路径的工程化落地,开发一个能够嵌入真实教学情境的斐济语语音评测原型系统,将底层的声学距离计算结果转化为能够有效指导学习者发音练习的上层教学反馈。

系统开发以支持斐济语语音练习场景为目标,聚焦于两大核心模块的设计:一是实现多粒度发音质量自动分析的评测模块,该模块封装了完整的 MFA-GFCC-DTW 计算流程,负责接收学习者语音并输出结构化的多层级(句、词、音素)发音质量得分;二是实现诊断信息有效呈现的教学反馈模块,为弥合“声学分数”与“教学指导”之间的鸿沟,该模块创新性地集成了大语言模型(LLM)API 接口,将评测引擎输出的量化、结构化数据动态生成为具有可解释性的自然语言诊断建议,使学习者不仅能够获得整体发音水平评价,还可以了解具体的发音问题所在,从而进行更有针对性的发音练习。

该原型系统的构建实现了评测算法的技术落地,并探索了将“声学诊断”转化为“纠错指导”的教学交互路径,具体技术架构、功能界面与关键代码实现将在第四章中展开详述。

3.4.4 教学应用验证

在完成语音评测原型系统开发后,本研究将其部署于某高校多语智慧学习平台的斐济语语音练习场景中,并邀请学习者参与系统试用,通过实际使用过程收集学习者对系统反馈效果与使用体验的评价。

在应用验证过程中,参与研究的学习者通过平台完成若干语音跟读练习任务,包括单词朗读和句子朗读两类练习,并查看系统提供的发音评分以及相关诊断信息。学习者完成系统试用后,本研究通过问卷调查的方式收集学习者的使用反馈,问卷中同时设置量表题与开放式问题,量表题主要用于了解学习者对系统反馈可理解性以及学习帮助程度等方面的量化评价数据;开放式问题则进一步收集学习者在系统使用过程中的具体体验与意见。对上述数据进行分析,不仅从学习者视角客观检验了该细粒度评测系统在低资源语种教学中的应用赋能价值,更为后续系统的迭代优化与应用模式

的提炼提供了详实的数据支撑。

3.5 数据收集工具

为全面地评估基于 MFA-GFCC-DTW 的细粒度语音评测路径在真实教学中的干预效果，本研究采用问卷调查作为主要数据收集方法，在问卷中同时设置量表题与开放式问题，以收集学习者的定量评价与定性反馈，旨在从多维视角获取学习者对系统反馈的主观感知、行为意向及改进建议。

3.5.1 问卷设计

本研究的问卷设计参考了技术接受模型（Technology Acceptance Model, TAM）、反馈理论（Feedback Model）以及系统可用性量表（System Usability Scale, SUS）等经典理论框架与研究成果融合了教育技术学与计算机辅助发音训练（CAPT）领域的相关理论框架，并结合语音学习情境进行调整。问卷维度的建构遵循从“信息接收”到“学习干预”再到“态度建立”的递进逻辑，从多个维度评估学习者对语音评测反馈机制的感知与评价。

针对系统输出的评测反馈，学习者首要面临的是信息解码过程。技术接受模型指出，技术的感知易用性（Perceived Ease of Use）会显著影响用户对该技术的接受程度与使用意愿，将其放入语音学习情境，即是要求系统所提供的评测反馈应当具备较高的可理解性，使学习者能够清晰解读发音评分与诊断信息，并准确识别自身发音问题。

69

然而，仅能理解反馈并不足以促成语言技能的有效提升。Hattie 与 Timperley 的反馈模型⁷⁰指出，有效反馈应当回答三个关键问题：学习目标是什么（Where am I going）、当前表现如何（How am I going）以及下一步如何改进（Where to next），为了回答“Where to next”，意味着语音评测系统不仅需要指出学习者的发音偏差，还应能够提供指导纠正练习的具体信息，从而帮助学习者进行针对性的发音改进。由此，本问卷引入“纠错支持”评估维度，以检验反馈信息在引导学习者识别发音问题并开展针对性练习方面的实际效能。⁷¹

在经历了反馈解读与纠错练习后，学习者是否愿意将该系统纳入常态化的学习链

⁶⁹ Tang, J., Zhai, Y., Li, L., Liu, P., & Deng, H. (2025). Mobile learning for less-commonly taught languages: design and application. *Journal of China Computer-Assisted Language Learning*, 5(1), 23-55.

⁷⁰ Wisniewski, B., Zierer, K., & Hattie, J. (2020). The power of feedback revisited: A meta-analysis of educational feedback research. *Frontiers in psychology*, 10, 487662.

⁷¹ Davis, F. D. (1989). Perceived usefulness, perceived ease of use, and user acceptance of information technology. *MIS quarterly*, 13(3), 319-340.

路，还取决于其对系统整体效能与可靠性的主观认可。在教育技术与人机交互研究中，系统可用性量表（System Usability Scale, SUS）被广泛用于评估用户对系统的使用体验以及整体满意度^{72,73}，参考 SUS 相关研究，本研究在问卷中设置“系统信任度”维度，以衡量学习者对系统自动评分合理性的信任感知及其持续使用该语音练习功能的意愿。

3.5.2 问卷内容

本研究设计的学习者评价问卷采用 Likert 五点量表形式（1=非常不同意，5=非常同意）。问卷共包含 9 个封闭式题项，紧密围绕上述三大维度展开：其中“反馈可理解性”旨在评估学习者解码并理解系统诊断信息的能力；“纠错支持”聚焦于反馈能否有效促发学习者进行针对性的错误定位与发音改善；“系统信任度”则综合测量学习者对评测结果的认可度及其在未来学习中的持续使用意愿。问卷的具体维度与题项分布如表 3.1 所示。

表 3.1 问卷的量表题内容（共 9 题）

评估维度	编号	问题
反馈可理解性 (Interpretability)	Q1	评测反馈能够帮助我知道自己哪些地方发音不准确。
	Q2	与仅给出整体评分相比，这种反馈形式更容易理解。
	Q3	与仅给出整体评分相比，这种反馈形式对我的语音学习更具有指导意义。
纠错支持 (Corrective support)	Q4	根据反馈提示，我能够尝试改正自己的发音问题。
	Q5	当反馈指出具体错误位置时，我更容易进行针对性练习。
	Q6	这种反馈方式有助于我逐步改善自己的发音。
系统信任度 (System credibility)	Q7	我认为评测结果基本能够反映我的发音情况。
	Q8	总体来说，我认为这种语音评测反馈对语音学习是有帮助的。
	Q9	如果多语智慧学习平台的语音练习系统提供这种反馈形式，我愿意继续使用该功能进行语音练习。

为弥补量化问卷在探究深层认知动机方面的局限性，本研究在问卷末尾设置了若干开放式问题，以进一步了解学习者在使用细粒度反馈过程中的真实体验，并收集学习者对系统优化的建议。

⁷² Cucchiarini, C., Neri, A., & Strik, H. (2009). Oral proficiency training in Dutch L2: The contribution of ASR-based corrective feedback. *Speech Communication*, 51(10), 853-863.

⁷³ Brooke, J. (1996). SUS-A quick and dirty usability scale. *Usability evaluation in industry*, 189(194), 4-7.

开放式问题主要围绕学习者认为最有价值的反馈信息、反馈帮助其发现发音问题的具体体验，以及对系统未来改进方向的建议等方面展开，具体问题内容如表 3.2 所示。

表 3.2 问卷的开放式问题内容（共 3 题）

评估维度	编号	问题
价值感知	Q9	你认为目前的反馈内容中最有帮助的地方是什么？
机制印证	Q10	这些反馈是否帮助你发现自己的发音问题？如果有，请举一个例子说明。
优化诉求	Q11	如果这种反馈形式在未来上线到多语智慧学习平台的语音练习系统中，你认为在反馈内容或呈现方式方面还有哪些可以改进的地方？

3.6 数据分析方法

数据分析是揭示教育技术干预有效性的关键环节。本研究在完成多维数据收集后，针对问卷中的量表题数据与开放式问题反馈数据分别采用定量与定性分析方法进行综合分析，以全面、客观地评估 MFA-GFCC-DTW 语音评测方法在斐济语教学中的实际应用效果。

针对量表类问卷数据，采用描述性统计（Descriptive Statistics）进行定量刻画，通过计算各个测量题项及核心维度的平均值（Mean）与标准差（Standard Deviation），系统量化学习者在“反馈可理解性”、“纠错支持”及“系统信任度”三个层面的整体评价水平与样本内部的离散程度，该统计方法能够直观映射出目标群体对系统各项功能的宏观感知，为客观评估该细粒度评测系统的可用性奠定了的量化基础。

对于问卷开放式问题所获得的文本反馈，采用主题分析法（Thematic Analysis）进行整理与归纳。主题分析法是一种广泛应用于社会科学和教育研究中的质性分析方法，其核心目标是在文本数据中识别、组织并解释具有意义的模式（themes），从而揭示研究对象所反映的关键经验与观点⁷⁴。本研究对学习者在开放式问题中的文本回答进行初步编码，并在此基础上归纳整理学习者关注的主要主题，如发音错误定位的有效性、系统使用体验以及对系统改进的建议等，进而对相关主题进行综合解释，为系统应用效果的评估提供补充性的质性证据。

通过量表题获得的量化数据与开放式问题反馈所形成的质性信息，本研究从定量

⁷⁴ Bangor, A., Kortum, P. T., & Miller, J. T. (2008). An empirical evaluation of the system usability scale. *Intl. Journal of Human - Computer Interaction*, 24(6), 574-594.

与定性两个层面，对所开发语音评测系统在斐济语教学中的应用价值进行综合分析与交叉验证，以提升研究结论的可靠性与解释力。

第4章 低资源语种语音评测系统设计与实现

4.1 斐济语语音教学需求分析

4.1.1 斐济语语音教学特点

斐济语（Fijian）属于南岛语系（Austronesian language family），其音节结构较为规则，多数音节由辅音与元音组合构成，但部分辅音在发音方式上与汉语普通话存在明显差异，学习者容易受到母语负迁移的影响，给发音学习带来一定困难。比如斐济语中常见的鼻音化辅音（prenasalized consonants），在一些词汇中，辅音在发音时会伴随明显的鼻音成分，例如在单词 *dua* 的发音中，字母 *d* 实际上带有鼻音起始特征，其发音接近 $[^nd]$ ，这种发音方式与汉语普通话中的辅音系统存在差异，中文母语学习者在朗读时往往容易忽略该鼻音成分，直接将其读为普通的 $[d]$ 音，从而产生发音偏差；斐济语字母 *c* 的发音也与汉语拼音中的对应字母不同，其通常表示齿间擦音 $/\delta/$ ，发音方式类似于英语单词 *this* 中的 *th*，而中文母语学习者在朗读时往往容易将其读为 $[s]$ ，从而导致发音错误。

在传统教学环境中，教师通常需要通过示范与纠正帮助学习者识别并改正这些错误；然而在数字化学习环境中，如果语音评测系统仅提供句级整体评价，学习者往往难以准确定位具体的发音问题，因此，能够识别词级甚至音素级发音偏差的自动语音评测机制，对于帮助学习者发现并纠正发音错误具有重要意义。

4.1.2 语音练习与细粒度评测反馈需求分析

在多语智慧学习平台的斐济语课程中，语音跟读练习是学习者进行口语技能建构的核心环节。当前平台基于移动学习环境构建了“示范—模仿—反馈”的交互闭环：学习者通过播放标准语音示范进行输入，随后录音完成跟读任务；系统对录音进行自动比对，并以“通过（Successful）”或“未通过（Failed）”的二元判定形式呈现结果。在此场景中，学习者虽被允许进行多次重复试音，但这种基于传统阈值的评测机制本质上属于结果导向的总结性评价。

尽管这种二元反馈能在一定程度上帮助学习者监测自身的整体达标情况，但在实际的语言技能习得过程中，其暴露出明显的“黑盒效应”与教学支持局限性：例如当学习者收到“未通过”的反馈时，现有系统缺乏对偏误位置与偏误类型的精准表征，

亦无法提供偏误性质的解释，由于斐济语的发音规则（如特有辅音组合等）对母语为汉语的学习者而言较为陌生，整体性的否定反馈会导致学习者陷入“知其错而不知其所以错”的认知困境，从而容易陷入“无效重复练习”，难以触发有效的自我纠错机制。

因此，本研究针对现有语音练习场景中诊断信息缺失的痛点，结合形成性评价理论与反馈模型，提出理想的斐济语语音评测系统必须完成从“单一结果评判”向“过程性教学支架”的转变，并满足以下两项核心评测需求：多粒度发音诊断需求，即系统需打破整体评分的局限，具备对学习者的语音流进行强制对齐与拆解的能力，从而提供“句-词-音素”多层级的精准错误定位；解释性纠错反馈需求，即系统不仅要指出“哪里读错了（Feed-back）”，更需要提供“为什么错”或“如何改进（Feed-forward）”的自然语言指导信息，以支持学生在练习过程中的自我纠错。

通过满足上述需求，系统才能真正在无教师实时干预的自主学习场景下，有效引导学习者将注意力集中于特定的薄弱音节或音素，进而实现发音技能的螺旋式提升。

4.1.3 评测维度与指标设计

在当前斐济语语音练习场景中，学习者多处于目标语学习的初级阶段，学习任务主要以模仿标准语音进行朗读为主，教学设计的首要目标是保障发音的可理解性与规范性。基于该目标，本文将语音评测的核心维度聚焦于发音准确度（Pronunciation Accuracy），即通过量化分析学习者语音（Learner Speech）与标准参考语音（Reference Speech）之间的声学特征相似度，对其发音质量进行科学评估。为打破传统整体评分的“黑盒效应”，更好地支持学习者精准定位偏误，本研究在评测设计中构建了遵循“从整体感知到局部聚焦”认知规律的多层级评测机制。

具体而言，评测维度将被解构为句级、词级和音素级三个层次：（1）句级评分用于反映学习者的宏观发音水平，提供整体表现的总结性反馈；（2）词级评分旨在缩小诊断范围，帮助学习者锚定语句中发音表现薄弱的具体词汇；（3）音素级评分则是最微观的诊断切入点，用于精准穿透并定位具体的发音偏差位置。通过这种自上而下的层级化评测设计，系统不仅能给出宏观评价，更为后续生成具有针对性的微观指导支架提供了数据锚点。

在评分机制方面，本研究通过计算学习者语音与标准语音之间的特征相似度来生成评测结果。系统取了差异化的指标分级策略，首先根据语音特征序列之间的相似度

得到发音评分,然后通过预设阈值将评分映射为不同等级:对于句级和词级评测结果,系统将评分划分为“不合格”“合格”“良好”“优秀”四个等级,以便对学习者的发音表现进行直观评价;对于音素级分析,则主要用于发音诊断,因此采用二分类判断的方式识别可能存在发音偏差的音素。当系统检测到某一音素的相似度低于预设阈值时,即认为该位置可能存在发音问题,并将相关信息作为诊断结果提供给后续反馈模块进行处理。

通过上述评测指标设计,系统能够在保证整体发音评价的同时,实现对具体发音问题的细粒度定位,从而为后续语音评测系统实现以及学习反馈生成奠定基础。

4.2 系统总体架构设计

4.2.1 系统设计目标

针对当前低资源语种语音学习中自动语音评测反馈粒度不足的问题,本文以斐济语语音学习场景为应用背景,设计并开发一套支持细粒度发音诊断的语音评测原型系统。系统的设计目标主要体现在以下几个方面:

(1) 系统需要支持斐济语语音学习中的自动评测功能。学习者在进行单词或句子跟读练习时,系统能够接收学习者录音输入,并通过自动语音分析方法对学习者的发音与标准语音之间的差异进行计算,从而生成客观的发音评测结果,为学习者提供即时反馈。

(2) 系统需要实现多层次的发音诊断能力。与仅提供整体通过或未通过评价的传统语音评测方式相比,本系统通过对学习者语音进行细粒度分析,在句级和词级层面生成发音评分,并在音素层面对可能存在发音偏差的位置进行诊断,从而帮助学习者更加准确地定位发音问题。

(3) 系统需要具备良好的反馈可解释性。在传统自动语音评测系统中,学习者往往只能获得数值化评分或简单等级评价,难以理解具体的发音问题。本研究在系统中引入解释性反馈生成机制,通过将语音评测得到的结构化结果转化为自然语言反馈,使学习者能够更清晰地理解发音偏差及其改进方向,从而提升语音练习的学习效果。

(4) 系统需要具有较好的计算效率与可扩展性。为减少在线评测过程中的计算负担,本研究在系统设计中将部分资源准备工作放在离线阶段完成,例如标准语音的强制对齐以及标准语音特征序列的预计算,从而在在线评测阶段能够更高效地完成语

音比对与评分过程。同时，该系统结构具有一定的通用性，在扩展到其他低资源语种语音学习场景时，仅需替换相应的语音资源即可实现迁移应用。

通过上述设计目标，本研究构建的语音评测系统不仅能够支持斐济语语音学习中的自动评测任务，还能够为学习者提供更加细粒度和可解释的发音反馈，从而提升语音练习的学习体验与学习效果。

4.2.2 系统总体架构

依据前述发音准确度多层次评测的设计目标，并充分考虑学习者在实际跟读场景中对反馈时效性的要求，本文构建了一个面向斐济语语音学习的自动语音评测原型系统，其总体架构如图 4.1 所示。该系统在拓扑结构上采用了“前后端解耦”的双层流水线设计，主要由离线资源准备层与在线语音评测与反馈层两部分协同构成。这种设计旨在通过离线预处理策略分担计算压力，从而保障在线交互时反馈的低延迟与流畅性。

在离线资源准备层中，系统首先构建语音评测所需的基础资源，包括标准文本、标准语音以及发音词典等。随后，系统利用强制对齐方法对标准语音与对应文本进行离线对齐，获得标准语音在词级和音素级的时间边界信息。同时，为提高在线评测效率，系统对标准语音提前进行声学特征提取，生成对应的特征序列，并与时间边界信息一同作为参考资源保存。通过上述离线处理过程，系统能够在后续在线评测过程中直接调用参考时间边界与标准语音特征序列，从而减少重复计算，提高系统运行效率。

在在线语音评测与反馈层中，当接收到学习者的实时录音后，系统触发在线处理数据流：首先将学习者语音与参考文本进行强制对齐，获得学习者语音在词级和音素级的时间边界；随后对学习者语音进行声学特征提取，并将学习者语音特征与离线阶段得到的标准语音特征进行比对，通过相似度计算方法量化评估两者在声学空间的差异程度；在获取基础比对数据后，系统通过预设阈值将相似度结果映射为不同等级的评分，在宏观层面（句/词级）输出发音评价，同时在微观层面（音素级）输出发音偏差识别与诊断。在此基础上，系统将上述结构化评测结果输入解释性反馈生成模块，通过自然语言生成方法将评测结果转化为学习者易于理解的反馈信息，最终呈现给学习者，形成完整的语音评测反馈流程。

通过上述系统架构设计，本研究构建了一条从“语音输入”到“细粒度诊断”，再到“解释性反馈”的完整闭环数据链路，为后续各关键功能模块的集成提供了稳固

的框架支撑。




图 4.1 语音评测原型系统架构图

4.2.3 系统关键功能模块设计

围绕系统总体架构中的数据流转逻辑，本研究构建的自动语音评测原型系统在功能层面上被解构为四个关键模块：语音对齐模块、声学特征提取模块、相似度计算与评分模块、反馈生成与呈现模块，前三个模块在后端依次串联，构成核心的评测引擎；后一个模块则作为前端的教学交互中枢，负责将底层计算结果转译为学习反馈。

语音对齐模块是实现细粒度评测的基础，其核心功能是将连续的物理语音信号切分为离散的语言学单位。当系统接收到学习者录音后，该模块以目标文本为约束，将学习者语音流进行强制时间对齐，获得词级和音素级的时间边界信息。这一处理使得学习者发音音频能够与离线阶段处理好的标准发音在同一时间尺度上建立起严格的“段对段”映射关系，从而为后续针对特定发音片段的局部比对确立了对齐基准。

在完成时间维度的锚定后，处理流程进入声学特征提取模块。原始语音信号中夹杂着诸多与发音质量无关的冗余信息（如音量差异、环境底噪等），该模块负责滤除这些干扰，并将原始语音信号转化为能够本质反映声道特征与发音部位的高维特征序列。在此过程中，系统复用了离线预置的标准语音特征序列，在线阶段仅需对学习者的实时输入进行特征提取，从而减少重复计算并提高系统运行效率，为下一步的相似度计算提供了标准化、纯净的输入数据。

依托前述模块提供的对齐边界与特征序列，相似度计算与评分模块沿“句-词-音素”的层级，逐级计算学习者特征序列与标准特征序列之间的动态距离，生成相似度指标。随后，模块内置的评分逻辑将抽象的相似度数值转换为结构化的诊断结果：在句、词层面映射至不同等级的评价（如不合格、合格、良好、优秀），在音素层面执行二分类判定对可能存在发音偏差的位置进行识别与标注。至此，系统完成了对发音行为的客观数据诊断。

最后，反馈生成与呈现模块负责将语音评测得到的结构化结果转化为学习者可理解的反馈信息。该模块包含多层次评测结果呈现、自然语言生成这两个子任务：在句级进行评价以便学习者直观了解整体发音水平，在词级对各个词汇进行评分从而帮助学习者识别发音表现较弱的词汇位置；当音素级分析识别到可能存在发音偏差的音素时，模块内部的生成机制会结合具体的偏误音素、所在词汇及发音规则，动态合成包含发音机理或改进建议的解释性文本提示，例如提示学习者注意某一音素的发音方式或重新听取标准语音示范。这种从“数值评分”向“指导语”的转译，真正落实了本研究对学习者自我纠错的支架式支持。

通过上述关键功能模块的协同工作，系统实现了从学习者语音输入到评测反馈输出的完整处理流程，不仅能够提供客观的发音评价结果，还能够帮助学习者理解发音问题及其改进方向，从而提升语音练习的学习效果，为斐济语语音学习提供了一种支持多层次发音诊断与解释性反馈的自动语音评测落地方案。

4.3 语音评测关键技术实现

本系统在传统基于声学特征比较的语音评测方法基础上，构建了一个由“语音文本对齐、声学特征提取与相似度计算”三个核心模块组成的语音评测流程。系统利用文本先验信息对学习者的语音进行音素级对齐，在此基础上提取语音声学特征，并通过动态时间规整算法计算学习者语音与标准语音之间的相似度，从而生成句级、词级以及音素级评分结果。

4.3.1 基于 MFA 的语音—文本强制对齐

在语音评测任务中，仅依赖整体声学特征的相似度计算难以准确定位学习者的局部发音偏差。为实现细粒度的发音诊断，系统必须在物理语音信号与目标语言学文本之间建立精确的时间映射关系。语音—文本强制对齐（Forced Alignment）技术能够在给定已知文本的先决条件下，自动确定语音流中各语言学单位（如词、音素）的起止时间边界。本研究选用当前语音研究领域应用广泛的 Montreal Forced Aligner (MFA) 作为核心工具，并针对斐济语低资源的现状，专门训练了定制化的声学模型，以为后

续的局部特征比对提供高精度的切分基准。

MFA 底层依托于 Kaldi 语音识别工具箱，其核心算法基于高斯混合模型与隐马尔可夫模型（GMM-HMM）架构。在具体对齐任务中，系统首先根据发音词典获取文本对应的隐马尔可夫状态序列；随后，利用高斯混合模型（GMM）估计语音流在各个时间帧上属于特定音素状态的发射概率（Emission Probability）；最后，采用维特比算法（Viterbi Algorithm）在所有可能的对齐路径中执行动态规划搜索，寻找语音帧序列与音素序列之间的全局最优匹配路径，从而精准界定每个音素的时间边界。

斐济语缺乏现成的开源声学模型，因此本研究从构建发音词典（Pronunciation Dictionary）、训练语料入手，开展了本地化的模型训练工作。由于斐济语属于典型的浅层正字法（Shallow Orthography）语言，字母与音素之间存在高度透明、稳定的对应关系，本研究采用字素到音素（Grapheme-to-Phoneme, G2P）直接映射策略，编写 G2P 规则将单词的拼写序列直接转换为基于 ARPA 音素集的发音序列（例如单词“bula”映射为音素序列“B UW1 L AA0”）；同时，本研究整合了 2700 余条斐济语母语者的朗读录音及其对应文本，构建了“音频+文本”的平行语料库，所有音频均经过重采样（16 kHz）与单声道标准化处理，并对文本进行基础清洗，如统一大小写、去除无关符号以及保证文本内容与语音内容一致，以确保语料质量满足声学模型训练需求。基于上述语料与词典，利用 MFA 引擎依次执行了单音素（Monophone）模型训练、三音素上下文相关（Triphone）模型训练以及发音特征自适应（SAT）等多轮迭代，最终输出了良好拟合斐济语声学规律的定制化声学模型。




图 4.2 Praat 软件中斐济语单词“bula”的语音与文本对齐结果（TextGrid）可视化界面

在实际的在线评测流水线中，系统将学习者的跟读录音、目标文本输入 MFA 对齐模块，并加载基于上述预训练的斐济语声学模型执行强制对齐，输出标准的 TextGrid 标注文件。TextGrid 是 Praat 软件常用的一种语音标注文件格式，采用层级

化的时间区间（Interval）数据结构，用于记录语音与文本之间的对齐信息，其内部包含词级（Word Tier）与音素级（Phone Tier）两个标注层级，每个层级由若干带有起止时间戳的区间构成。例如，在音素层级中，系统会精确标注每个音素对应的语音片段及其时间边界，从而实现对语音信号的细粒度时间对齐。图 4.2 展示了在 Praat 软件中打开 TextGrid 文件后的可视化界面。

通过解析 TextGrid 文件，系统能够提取出结构化的时间边界，使得原本连续的测试语音被精准地“切割”为与标准发音严格对应的微观切片，从而打通了从“宏观输入”到“微观比对”的数据链路，为后续在特定时间窗内进行特征提取与动态时间规整（DTW）计算提供了决定性的时间定位依据。

4.3.2 基于 GFCC 的声学特征提取

在完成语音-文本强制对齐后，系统需从分段后的语音信号中提取能够高度表征发音生理特征的声学向量，用于后续学习者语音与标准语音之间的相似度计算。语音的特征提取（Feature Extraction）的本质是通过信号变换，将高维、非平稳的原始语音时域信号转换为能够刻画声道几何形状且具备鲁棒性的低维特征序列，从而降低计算复杂度。在自动语音评测领域，倒谱特征（cepstral features）是最常用的一类语音特征，其中梅尔频率倒谱系数（Mel-Frequency Cepstral Coefficients, MFCC）曾是主流的特征表征手段，但考虑到本研究面向移动学习场景下的复杂环境噪声，本文引入了更具生物听觉鲁棒性的伽马通频率倒谱系数（Gammatone Frequency Cepstral Coefficients, GFCC）。

1. MFCC 的基本原理与局限性分析

MFCC 的基本思想是模拟人耳听觉系统对频率的非线性感知特性，通过于梅尔刻度（Mel Scale）对语音信号进行滤波与压缩表示，其与物理频率 f （单位是 Hz）的映射关系公式如下：

$$f_{mel} = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right) \quad (1)$$

在计算流程上，MFCC 通过对分帧加窗后的信号执行快速傅里叶变换（FFT）获取功率谱，随后利用一组线性间隔排列的三角滤波器组进行频域能量积分，最后通过离散余弦变换（DCT）实现倒谱去卷积，通过这一系列处理，语音信号在频谱上的能量分布被转换为一组低维倒谱系数，从而形成能够表征语音音色与发音特征的声学表示。在早期的计算机辅助发音训练（CAPT）系统中，MFCC 由于计算效率高、实现成熟，被广泛用于语音识别与语音评测任务。然而，MFCC 的局限性在于其三角滤波器是对称且线性分布的，使得其在噪声环境中的鲁棒性相对有限，当语音采集环境

中存在较明显的背景噪声（如户外风噪、环境人声或设备噪声）时，加性噪声容易影响语音频谱的能量分布，从而导致特征失真。而在移动学习场景中，学习者往往通过手机或平板设备进行语音跟读练习，录音环境难以保持实验室条件下的安静状态，可能导致 MFCC 提取的特征分布产生严重偏移，进而降低语音评测结果的稳定性。

2. GFCC 的技术优势与算法流程

针对 MFCC 鲁棒性不足的问题，本文采用 GFCC 特征作为底层声学表示。GFCC 的设计灵感来源于心理声学中的伽马通（Gammatone）滤波器组，其脉冲响应函数能够更精确地模拟人耳外周听觉系统的滤波特性。相较于 MFCC 使用的三角滤波器，GFCC 的滤波器带宽随中心频率非线性增长，较好地还原了耳蜗基底膜的频率选择性，生理拟合度更高；同时，由于 Gammatone 滤波器在频域具有非对称的包络特性，能够更有效地抑制环境中的宽带噪声与加性干扰，保持特征在噪声场中的聚类稳定性，达到更强的环境鲁棒性。

Gammatone 滤波器的时域脉冲响应 $g(t)$ 定义如下：

$$g(t) = at^{n-1}e^{-2\pi Bt} \cos(2\pi f_c t + \phi), \quad t \geq 0 \quad (2)$$

该公式描述了一个随时间衰减的余弦脉冲信号，其中 a 为滤波器增益， n 为滤波器阶数， B 为等效矩形带宽（ERB）， f_c 为中心频率， ϕ 为初相位。

在本研究的斐济语语音评测流水线中，GFCC 充当了“声学指纹”的角色，系统对标准语音与学习者录音执行同构的 GFCC 提取，将两段长度不等、语速各异的语音信号转化为在特征空间具有可比性的特征矩阵，其的具体提取流程如下：首先对预处理后的语音信号执行分帧（25ms）与加窗（Hamming Window）处理；随后进行傅里叶变换（FFT）获取频谱；接着利用由 64 个通道组成的 Gammatone 滤波器组对频谱进行卷积，提取各频段的能量包络；最后经过对数压缩与 DCT 变换，获得 13 维静态倒谱系数及其一阶、二阶差分特征，最终形成 39 维的特征向量序列。通过引入 GFCC 特征，本系统在保持传统特征比较方法计算效率优势的同时，提高了语音评测在真实学习环境中的鲁棒性，为后续细粒度语音评测提供了更加稳定的声学表示基础。

4.3.3 基于 DTW 的相似度计算与评分生成

在完成语音特征提取后，需要进一步量化评估学习者语音与标准参考语音之间的相似程度。在真实的朗读场景中，由于不同学习者的语速慢快、停顿习惯及发音节奏存在天然差异，导致两段语音即使内容完全一致，其特征序列在时间轴上也会呈现非线性偏移。若采用传统的逐帧欧氏距离对比，将产生显著的匹配误差，因此本研究采用动态时间规整（Dynamic Time Warping, DTW）算法，通过非线性时间对齐技术，

寻找两条特征序列间的最佳匹配路径，进而生成客观的发音相似度指标，并在此基础上生成发音评分结果。

1. DTW 算法原理与距离计算

DTW 是一种经典的时间序列匹配算法，最早应用于语音识别与语音模板匹配任务，其核心思想是通过动态规划（Dynamic Programming）方法，在两个时间序列之间寻找一条累计距离最小的匹配路径，从而实现不同长度序列之间的最优对齐。在语音评测任务中，DTW 可以将学习者语音特征序列与标准语音特征序列进行动态匹配，即使两段语音在时长或语速上存在差异，也能够通过时间轴上的“拉伸”或“压缩”实现合理对齐，从而更准确地反映两段语音在声学特征上的差异程度。设标准语音的特征序列 R （reference）为：

$$R = \{r_1, r_2, \dots, r_i, \dots, r_N\}$$

学习者语音的待测特征序列 L （learner）为：

$$L = \{l_1, l_2, \dots, l_j, \dots, l_M\}$$

其中， r_i 与 l_j 分别为对应时间帧上的 GFCC 特征向量。然后，构建一个 $N \times M$ 的距离矩阵，矩阵中各元素 $d(i, j)$ 代表两个特征向量间的局部欧氏距离：

$$d(r_i, l_j) = \sqrt{\sum_{k=1}^K (r_{i,k} - l_{j,k})^2} \quad (3)$$

随后通过动态规划计算累计距离矩阵，并在矩阵中寻找累计距离最小的对齐路径，其递推状态转移方程如下：

$$D(i, j) = d(r_i, l_j) + \min \{D(i-1, j), D(i, j-1), D(i-1, j-1)\} \quad (4)$$

其中 $D(i, j)$ 表示从序列起点到当前位置的最小累计距离，通过不断迭代计算，最终得到的 $D(N, M)$ 即为两条序列在最优对齐路径下的总累计距离，其反映了学习者语音与标准语音之间的整体差异程度：距离值越小，说明两段语音在声学特征上的相似度越高，发音越接近标准示范

2. 距离归一化与线性评分映射

在获得特征序列之间的距离值后，还需要将其转换为更易理解的百分制评分。由于 DTW 输出的是累计距离，其数值大小受语音时长（帧数）的影响极大，长语音序列的累积距离往往大于短序列，为消除时长冗余，本研究首先计算平均归一化距离（Normalized Distance）：

$$\bar{d} = \frac{D(N, M)}{N + M} \quad (5)$$

其中 $D(N, M)$ 表示 DTW 累积距离， N 与 M 分别表示两段语音特征序列的长度，这种归一化处理使不同长度语音片段之间的距离具有了可比性。在此基础上，为进一步消除不同层级（句子、词、音素）距离分布差异的影响，本文采用 Z-score 标准化方法对距离进行标准化处理：

$$z = \frac{\bar{d} - \mu}{\sigma} \quad (6)$$

其中 μ 表示对应层级距离分布的均值， σ 表示标准差。该步骤将原始距离转换为以均值为中心的标准化距离，从而增强评分映射对距离变化的敏感性。

为了将标准化距离转换为直观的 0-100 分制评分，本研究采用线性评分映射函数：

$$Score = B - kz \quad (7)$$

其中 B 为基准评分（baseline score），表示平均水平发音对应的评分； k 为斜率参数（slope parameter），用于控制评分对距离变化的敏感程度。考虑到句子、词与音素三个层级的评测稳定性存在差异，本研究为不同层级设置了不同的参数，例如，音素层级由于语音片段较短、特征波动较大，因此采用相对较小的斜率参数 k ，以避免过度惩罚局部误差。

通过上述步骤，DTW 声学距离被转换为稳定且易于理解的百分制语音评测分数，距离越小表示学习者发音越接近标准语音，对应评分越高；距离越大则表示发音偏差较大，评分相应降低。

3. 基于时间窗截取的多层次评分实现

依托前述环节所获得的 TextGrid 时间标注信息以及声学特征信息，可以截取对应的特征序列片段进行局部 DTW 计算，实现从整体到局部的多层次评分生成：

（1）句级评分：直接将整段录音的特征矩阵与标准语音的特征矩阵进行 DTW 动态匹配，计算全局相似度，用于反馈学习者的整体发音表现；

（2）词级/音素级评分：针对更细粒度的评测，系统根据 TextGrid 提供的各语言学单位（词、音素）的起始时间 T_{start} 与终止时间 T_{end} ，计算对应的帧索引范围 F_{start} 与 F_{end} ，并据此从全局特征矩阵中精准截取对应的局部特征子矩阵；随后将截取的局部特征子矩阵与其对应的标准参考片段进行局部 DTW 计算，在特定词/音素的时间窗内寻找声学差异，将差异分值与预设的错误触发阈值进行比对，帮助定位语句中发音薄弱的特定词汇，或标记“疑似发音偏误”的特定音素。

（3）音素级诊断：针对最细粒度的音素边界（Phone Tiers），执行微观片段比对，

系统在这一层级不仅输出相似度分值，还会将分值与预设的错误触发阈值进行比对，若某音素评分低于阈值，则标记为“疑似发音偏误”。

4.3.4 算法流程伪代码

```
1 Algorithm 1 MFA-GFCC-DTW-based Pronunciation Evaluation
2
3 Input:
4   x_l      : 学习者朗读音频
5   x_r      : 标准朗读音频
6   T        : 对应朗读文本
7   D        : MFA 发音词典
8   M        : MFA 声学模型
9
10 Output:
11   S_sent   : 句子级得分 (0-100)
12   S_word   : 词级得分集合 (0-100)
13   S_phone  : 音素级得分集合 (0-100)
14
15
16 Procedure:
17
18   // 将标准音频与学习者音频分别和朗读文本进行 MFA 强制对齐
19   G_r <- MFA_Align(x_r, T, D, M)
20   G_l <- MFA_Align(x_l, T, D, M)
21   // 根据 TextGrid 对齐结果切分单词与音素片段
22   W_r, W_l <- Segment_By_Level(G_r, G_l, level = "word")
23   P_r, P_l <- Segment_By_Level(G_r, G_l, level = "phone")
24   // 计算句子级得分
25   S_sent <- Score_By_GFCC_DTW(x_r, x_l)
26   // 逐词提取 GFCC 特征，计算 DTW 距离并映射为百分制得分
27   S_word <- empty set
28   for each (w_r, w_l) in Match(W_r, W_l) do
29     s_w <- Score_By_GFCC_DTW(w_r, w_l)
30     S_word <- S_word union {(Label(w_r), s_w)}
31   end for
32   // 逐音素提取 GFCC 特征，计算 DTW 距离并映射为百分制得分
33   S_phone <- empty set
34   for each (p_r, p_l) in Match(P_r, P_l) do
35     s_p <- Score_By_GFCC_DTW(p_r, p_l)
36     S_phone <- S_phone union {(Label(p_r), s_p)}
37   end for
38
39   return S_sent, S_word, S_phone
```

为更加清晰地呈现本文语音评测算法的整体执行过程，本节对 MFA-GFCC-DTW 方法的核心流程进行伪代码描述。该算法以学习者朗读音频、标准朗读音频及对应朗读文本作为输入，首先利用 MFA 将语音信号与文本内容进行强制对齐，并依据对齐结果获得句子、单词和音素层面的时间边界；随后，在不同粒度的语音片段上分别提取 GFCC 声学特征，并通过 DTW 算法计算学习者发音与标准发音之间的声学距离；最后，将距离值映射为百分制发音得分，输出句子级、词级和音素级评测结果。

4.4 细粒度反馈生成机制

在自动语音评测系统中，底层声学算法输出的相似度距离或百分制评分仅属于“机器数据”，若直接呈现给学习者，往往会产生明显的认知鸿沟。从教育评价理论的角度来看，反馈在学习过程中具有关键作用，形成性评价理论强调在学习过程中提供具有诊断意义的信息，以促进学习的持续改进；Hattie 与 Timperley 的反馈模型也指出，有效的反馈不仅能够回答当前表现如何（How am I going），还必须能够回答下一步应该如何改进（What should I do next）。因此，在语音评测系统中，如何将底层声学指标转化为具有教学意义的反馈信息，是影响系统教学有效性的重要环节。基于此，本研究在语音评测系统中设计了细粒度反馈生成机制，通过对多层级的 DTW 评分进行结构化封装并集成大语言模型（LLM）进行教学反馈重构，将声学评测结果转化为面向学习者的自然语言提示，实现从“声学评分”到“教学反馈”的转化过程，从而有效帮助学习者在练习中自我纠错。

4.4.1 评测结果的结构化与诊断决策

在完成多层级的声学比对计算后，系统生成的相似度分值仍处于离散的原始数据状态，为了将这些机器数据转化为大语言模型可处理的教学指令，需要通过结构化的预处理对评测结果进行封装，并在此过程中嵌入诊断决策逻辑。本研究构建了基于评分阈值触发的诊断决策框架，将底层 DTW 相似度分值映射为具有教学意义的判定状态，预设句级、词级、音素级三层递进的诊断阈值，只有当发音评分低于相应阈值时才会触发下一层的更细粒度诊断，从而避免评测系统的“过度提醒”，造成反馈信息的冗余，给学习者增加认知负荷。

在此决策框架下，评测过程中的关键要素会被集成于统一的 JSON 结构化对象中（见如下代码块示例），该对象记录了朗读文本以及各层级评测的发音得分，即整句、每个单词、每个音素的得分，并根据预设阈值对重点词汇进行了标注：发音得分显著高于阈值的单词被归类为“优势词汇（strong_words）”，作为后续反馈中正面激励的素材；而低于阈值的单词则被精准锚定为“弱项词汇（weak_words）”，并进一步

关联其内部存在偏误的具体音素。

这种结构化处理将原本碎片化的声学评分整合为了具有逻辑关联的“诊断包”，提供了诊断决策的初步解释，为后续利用大语言模型（LLM）将声学指标转译为具有高度概括性、针对性的自然语言反馈奠定了标准化的输入基础，实现了从“数值计算”向“教学诊断”的平滑过渡。

```
1 {
2   "sentence_id": "learner1_question_001",
3   "reference_text": "bula",
4   "status": "ok",
5   "sentence": {
6     "score_relative": 81.78,
7     "needs_diagnosis": true,
8   },
9   "strong_words": [],
10  "weak_words": [
11    {
12      "word": "bula",
13      "word_score_relative": 72.5,
14      "weak_phones": ["b"]
15    }
16  ],
17 }
```

4.4.2 基于 LLM 的自然语言反馈生成

在获得结构化评测结果之后，系统的核心任务转向如何将这此量化指标转化为学习者可理解、可操作的教学建议。当前主流预训练大语言模型（Large Language Models, LLM）已具备丰富的世界知识与人类语言体系储备，无需额外微调，仅通过精心设计的提示工程（Prompt Engineering），即可依托上下文学习（In-Context Learning, ICL）能力调用对应语音知识，生成符合预设角色与格式要求的反馈内容，因此本研究引入 LLM 作为反馈生成的基座，利用其强大的文本生成与语义理解能力，将结构化评测结果作为输入，引导模型生成简短、清晰且具有指导意义的自然语言反馈，从而实现从声学指标到教学指导的有效转换。

在反馈生成策略设计上，本研究遵循认知负荷最小化原则。Sweller 的认知负荷理论（Cognitive Load Theory, CLT）认为，人类工作记忆容量有限，如果学习材料呈现的信息过多或结构复杂，容易造成过高的认知负荷，从而影响学习效果^[68]，因此在教学信息呈现过程中，应尽量减少与学习目标无关的信息干扰，使学习者能够将有限的

认知资源集中于关键学习任务之上。基于这一理论，本研究在反馈生成机制中设计了一套动态触发的递进式干预策略。

具体而言，整句发音质量优异且各词汇无明显偏差时，系统仅展示简洁正面评价，不调用模型生成额外文本，减少不必要的信息呈现；若整体发音较好但个别词汇存在偏差，系统输出轻量级反馈，仅提示学习者关注对应词汇并引导其聆听标准发音示范；仅当发音评分低于预设诊断阈值且存在稳定的音素偏误特征时，才触发最深层级的音素诊断反馈；同时严格控制反馈详略以避免信息过载，使单次练习仅聚焦 1-2 个核心发音问题，引导学习者将注意力资源集中于到最具改进价值的发音偏误上。与仅提供评分结果相比，该机制能够帮助学习者理解评分不理想的可能原因，并在后续练习中进行更有针对性的调整。

为保证反馈内容兼具语音教学专业性与中文母语者的认知适配性，本研究构建了高度结构化的提示词模板，为模型赋予“精通汉-语音对比分析的语音教学助手”专业角色，并明确规定反馈的生成逻辑与约束条件：要求模型在总结时先从整体发音稳定性切入，再逐步聚焦局部偏误；严格依据 JSON 格式的诊断证据链（如 `strong_words`、`weak_words` 等字段）进行分析，禁止无依据推断。同时，提示词中嵌入斐济语拼写-音标映射规则（如字母 *c* 对应[ɔ]、字母 *b* 对应前置鼻音化[^mb]），使模型能够从上下文学习中理解斐济语特有发音规律，从而生成包含发音机理说明的精准化深层反馈。例如，当学习者朗读词汇 *bula*（你好）时，若系统检测到音素/b/的声学特征与标准模型存在显著偏离，且词汇评分触发干预阈值，将调用大语言模型结合提示词中的专业知识，生成兼具鼓励性与指向性的反馈。这种转译过程将抽象的声学特征差异“翻译”为学习者可感知、可操作的教学指导，充分体现了生成式人工智能在个性化、支架式语音反馈生成中的应用价值。

系统在前端界面中以可视化方式呈现评测结果。如图 4.3 所示，界面通过不同颜色对句子中的词汇、音素进行标注，用以区分发音表现的不同等级，并在下方通过自然语言形式提供针对性的发音建议，从而帮助学习者理解评分结果背后的具体原因。



图 4.3 语音评测反馈界面示例，其中绿色标注代表发音正确；黄色代表发音达标；红色代表发音有误，建议重读。

第 5 章 教学验证

5.1 应用实施过程

本研究以某高校多语智慧学习平台中的斐济语课程为研究情境，对本文开发的细粒度语音评测原型进行应用验证。实验对象为 6 名正在学习斐济语的学生，这些学习者此前已在课程学习过程中使用过平台原有的语音练习模块，对传统语音评测系统仅提供句级评分反馈的方式具有一定使用经验。

在实验任务中，每位学习者根据提供的标准音频完成 6 条斐济语句子的跟读练习，练习界面如图 5.1 所示；随后系统对学习者的语音进行自动评测并生成反馈结果，学习者获取反馈内容后，学习者填写问卷，对评测反馈的学习支持效果进行评价。本次实验共产生三类数据：（1）6 名学习者的语音数据，共计 60 条语音样本；（2）评测系统自动生成的句级打分结果以及细粒度反馈信息；（3）通过问卷调查收集的学习者对评测反馈的主观评价数据，为后续分析提供依据。




图 5.1 语音跟读练习界面示例

5.2 语音评测案例分析

为了更直观地展示本文提出的细粒度语音评测方法在实际语音学习场景中的应用效果,本节选取两例典型案例,对系统生成的评测结果进行分析,详见表 5.1 和表 5.2。

表 5.1 学习者辅音发音偏差案例分析

案例一：辅音发音偏差	
朗读文本	<i>Bula.</i> (你好)
学生发音问题	学生没有发出/b/前面的鼻音,而是近似中文里“不”的辅音,导致系统检测到对应音素的发音评分偏低。
系统生成反馈	读得真棒! 有个小建议,下次多注意开头 <i>b</i> 的发音,这个音在斐济语里会带一点鼻音,可以试着先轻轻带一点 <i>m</i> 的感觉,再自然过渡到 <i>b</i> ,不要直接读成普通的 <i>b</i> 。

表 5.2 学习者元音发音偏差案例分析

案例二：元音发音偏差	
朗读文本	<i>e lagasere tiko na tagane</i> (男人在唱歌)
学生发音问题	学生在元音/e/的结尾带了鼻音,听起来像“en”,但是其后的单词 <i>lagasere</i> 开头的辅音/t/并不带鼻音,因此这样的发音是错误的,导致系统检测到 <i>e</i> 的发音打分偏低;同时,学生的 <i>tagane</i> 单词发音标准,评分很高。
系统生成反馈	整体读得比较自然,句子的节奏也不错。 <i>tagane</i> 这个单词的发音很好,听起来比较清晰,继续保持! 建议稍微注意句首 <i>e</i> 的发音,这个音要干净地结束,不要在后面带出一点鼻音。有些同学在练习 <i>e dua</i> 的时候习惯把它读成类似“en dua”的感觉,如果把这个习惯带到这里,就可能会读成“en lagasere”,这样就不太准确了。

从上述案例可以看出,与传统仅提供整体评分的语音评测方式相比,本文提出的细粒度语音评测方法能够在句级评测基础上进一步定位发音问题,并通过设计带有斐济语发音规则、与中文母语者易错要点作为上下文信息的提示词来调用 LLM,生成

具有教学指导意义的反馈信息，这种反馈方式有助于学习者识别具体发音错误，从而支持针对性的语音练习。

5.3 问卷结果分析

为了进一步了解学习者对细粒度语音评测反馈的使用体验，本研究在实验结束后向参与实验的学习者发放问卷，对其主观体验进行调查，共回收有效问卷 6 份。问卷采用 Likert 五级量表形式，其中 1 表示“非常不同意”，5 表示“非常同意”，量表题从反馈可理解性、纠错支持以及系统信任度三个维度设计，共包含 9 道题目；问卷末尾还设置了开放式问题，用于收集学习者对评测系统反馈内容及其呈现方式的具体意见与改进建议，从而进一步补充量化数据难以反映的学习体验信息。

问卷量表题的统计结果如表 5.3 所示。从统计结果可以看出，学习者对本系统反馈机制整体评价较高，各维度平均得分均高于 4.5。其中，反馈可理解性维度得分最高（ $M=4.94$ ），说明学习者普遍认为该系统提供的词级与音素级反馈能够清晰地指出发音问题，相较于仅给出整体评分的评测方式，这种细粒度反馈更容易被理解，也更具学习指导意义；在自我纠音支持维度（ $M=4.67$ ）上，学习者普遍认为，当系统能够明确指出具体的错误位置时，更容易进行针对性练习，从而逐步改善自己的发音表现，这一结果表明，本研究提出的细粒度评测与反馈机制不仅能够提供评价结果，还能够一定程度上支持学习者进行自我纠正，体现出其在语音学习中的形成性评价价值；在系统信任度与使用意愿维度（ $M=4.56$ ）上，学习者总体认可系统评测结果，并表示如果该功能在学习平台上线，愿意继续使用该功能进行语音练习，说明该评测机制在学习者主观体验层面具有较好的可接受性。

表 5.3 问卷量表题的统计结果（各评价维度平均分）

评价维度	平均打分
反馈可理解性	4.94
纠错支持	4.67
系统信任度	4.56

通过对开放式问题的结果进行整理，可以将学习者的反馈归纳为以下三个方面：

（1）细粒度错误定位被认为最有价值：多名学习者指出，评测反馈能够明确指出具体的发音问题的位置，是当前反馈中最有帮助的部分，例如“能够指出某个特定音节的问题”、“具体到音位的指导很有帮助”。

(2) 反馈能够帮助学习者发现此前未注意到的发音问题: 部分学习者在问卷中提到, 通过系统反馈首次意识到某些具体发音问题, 例如“评测反馈提示某个辅音没有带鼻音, 这是之前没有注意到的”, 本研究提出的基于 LLM 的反馈生成模块不仅能够指出错误位置, 还能够提供一定程度的发音提示, 从而帮助学习者理解发音偏差的原因, 这种具有解释性的反馈有助于学习者进行针对性练习, 提高语音训练效率。

(3) 学习者提出的改进建议也为评测系统未来优化提供了参考方向, 例如增加对语流、节奏或自然度等方面的评价、优化反馈展示方式以及完善练习流程等。

综合量化与质性数据可以发现, 细粒度语音评测反馈机制得到了参与体验的学习者的普遍认可, 问卷的量化结果显示该反馈方式在可理解性、自我纠音支持以及系统可信度方面均获得较高评价; 质性数据则进一步表明, 学习者特别认可系统能够定位具体错误位置这一功能, 并认为这种反馈形式能够帮助其更清晰地发现并改进发音问题。该结果进一步证明了本研究提出的基于 MFA-GFCC-DTW 的细粒度语音评测与反馈机制在学习者体验层面具有较好的可接受性和教学支持价值, 为自动语音评测技术在低资源语种语音教学中的应用提供了有益探索。

第6章 总结与展望

6.1 本文研究工作总结

针对低资源语种语音教学中普遍存在的标准语音资源不足、教师个别化纠音支持有限以及自动语音评测反馈粒度较粗等问题,本文以斐济语为研究对象,围绕低资源条件下如何构建具有教学支持价值的自动语音评测系统展开研究,在梳理自动语音评测技术发展路径及其在低资源语种中适配局限的基础上,立足某高校多语智慧学习平台斐济语课程的真实教学场景,按照“资源构建—方法设计—系统实现—应用验证”的思路,探索了一条面向低资源语种朗读场景的细粒度语音评测与反馈实现路径。主要工作总结如下:

(1) 本文完成了斐济语语音评测所需基础资源的整理与构建工作,包括标准朗读语音语料、对应文本以及斐济语发音词典,并利用 Montreal Forced Aligner (MFA) 工具实现语音与文本之间的自动强制对齐,获得词级和音素级时间边界信息。上述工作作为后续评测算法的实现提供了必要的数据库和技术支撑,也在一定程度上丰富了斐济语语音教学可复用的数字资源;

(2) 本文设计并实现了基于 MFA-GFCC-DTW 的细粒度语音评测方法,该方法综合利用已知文本信息、标准示范语音以及有限的母语者语音资源,在不依赖大规模发音偏误标注语料的前提下,实现了学习者语音的句级评分、词级评分与音素级错误定位。与传统仅输出整体分数或通过/未通过结果的粗粒度评测方式相比,该方法能够更准确地揭示学习者发音问题所在,从而为后续反馈生成提供更细致的诊断依据;

(3) 本文设计了细粒度反馈机制,针对传统语音评测系统“有评分、少指导”的局限,本文将结构化评测结果与大语言模型相结合,尝试把句级、词级和音素级诊断信息转化为学习者可理解的自然语言反馈,使系统不仅能够指出发音问题的位置,还能够结合具体词汇和发音特点,为学习者提供具有一定解释性和指导性的改进建议。由此,语音评测反馈由单纯的结果性输出进一步转向对学习过程的支持,增强了系统在自主练习情境中的教学价值。

(4) 基于上述方法与机制,本文开发了斐济语语音评测原型系统,并在真实学习情境中进行了初步应用验证。通过组织学习者参与语音跟读练习,并通过问卷调查的方式收集其对反馈可理解性、纠错支持作用及使用体验的评价,本文对系统的教学支持价值进行了初步考察。

总体来看,本文围绕低资源语种语音教学中的反馈不足问题,完成了从资源构建、方法设计到原型实现与应用验证的一整套研究工作,形成了一条具有一定可操作性与

可迁移性的细粒度语音评测技术路径,可为多语智慧学习平台其他低资源语种的语音评测开发提供参考。

6.2 未来展望

本文围绕低资源语种语音教学中的反馈不足问题,完成了斐济语语音评测资源构建、细粒度评测方法设计、反馈机制开发以及原型应用验证等工作,所提出的“强制对齐+特征比对+细粒度反馈生成”的技术路径,对多语智慧学习平台中的其他低资源语种也具有一定的参考价值。未来可在不同语种中开展迁移应用与适配研究,进一步验证该路径在低资源语种语音教学中的普适性与推广潜力。然而,受研究周期与现实条件所限,本文的研究工作仍然存在进一步完善的空间:

(1) 本文所使用的斐济语母语者语音资源规模仍较为有限,现有语料在说话人数量、录音环境以及词汇覆盖范围等方面还有待进一步扩充,这在一定程度上会影响声学模型的鲁棒性与系统对更丰富学习内容的适配能力;当前构建的发音词典亦然,虽然能够满足已有语音评测任务的基本需求,但在词汇覆盖的完整性和部分发音规则的细化处理方面仍可继续完善,以更好地支撑系统在更复杂教学内容中的应用。

(2) 本文采用的评分机制仍有进一步优化的空间。当前系统主要依据学习者语音与标准语音之间的 DTW 距离进行相似度计算,并在此基础上实现句级、词级评分与音素级诊断,但如何将底层距离值更加稳定、合理地映射为 0-100 分的可理解评分,使其更准确地反映学习者的实际发音水平,仍然是后续需要深入研究的问题。未来可以结合更多人工标注样本、教师评价结果或学习者真实使用数据,对评分映射函数和阈值设置进行进一步校准,从而提升系统评分结果的解释性与可信度。

(3) 在后续研究中,还可继续推进本文技术路线在更真实教学环境中的落地与拓展。一方面,可在现有基础上持续收集斐济语母语者语音数据,进一步训练和优化声学模型,并同步完善发音词典与语音资源库,提升系统整体性能;另一方面,可进一步优化反馈呈现方式与交互流程,使细粒度评测结果能够更自然地嵌入学习者的跟读练习过程,形成更加完整的“评测-反馈-修正-再练习”闭环。

参考文献

1. 英文文献

- [1] Black, P., & Wiliam, D. (1998). Assessment and classroom learning. *Assessment in Education: principles, policy & practice*, 5(1), 7-74.
- [2] Hattie, J., & Timperley, H. (2007). The power of feedback. *Review of Educational Research*, 77(1), 81-112.
- [3] Derwing, T. M., & Munro, M. J. (2005). Second language accent and pronunciation teaching: A research-based approach. *TESOL quarterly*, 39(3), 379-397.
- [4] Gor, K., & Vatz, K. (2009). Less commonly taught languages: Issues in learning and teaching. *The handbook of language teaching*, 234-249.
- [5] Tang, J., Zhai, Y., Li, L., Liu, P., & Deng, H. (2025). Mobile learning for less-commonly taught languages: design and application. *Journal of China Computer-Assisted Language Learning*, 5(1), 23-55.
- [6] Warschauer, M., & Healey, D. (1998). Computers and language learning: An overview. *Language teaching*, 31(2), 57-71.
- [7] Rogerson-Revell, P. M. (2021). Computer-assisted pronunciation training (CAPT): Current issues and future directions. *Relc Journal*, 52(1), 189-205.
- [8] Isaacs, T., & Harding, L. (2017). Pronunciation assessment. *Language Teaching*, 50(3), 347-366.
- [9] Neri, A., Mich, O., Gerosa, M., & Giuliani, D. (2008). The effectiveness of computer assisted pronunciation training for foreign language learning by children. *Computer Assisted Language Learning*, 21(5), 393-408.
- [10] Witt, S. M., & Young, S. J. (2000). Phone-level pronunciation scoring and assessment for interactive language learning. *Speech communication*, 30(2-3), 95-108.
- [11] Leung, W. K., Liu, X., & Meng, H. (2019, May). CNN-RNN-CTC based end-to-end mispronunciation detection and diagnosis. In *ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 8132-8136). IEEE.
- [12] Li, K., Qian, X., & Meng, H. (2016). Mispronunciation detection and diagnosis in 12 english speech using multidistribution deep neural networks. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 25(1), 193-207.

- [13] Besacier, L., Barnard, E., Karpov, A., & Schultz, T. (2014). Automatic speech recognition for under-resourced languages: A survey. *Speech communication*, 56, 85-100.
- [14] Adda, G., Stüker, S., Adda-Decker, M., Ambouroue, O., Besacier, L., Blachon, D., ... & Zerbian, S. (2016). Breaking the unwritten language barrier: *The BULB project*. *Procedia Computer Science*, 81, 8-14.
- [15] Eskenazi, M. (2009). An overview of spoken language technology for education. *Speech communication*, 51(10), 832-844.
- [16] DeKeyser, R. (2020). Skill acquisition theory. In *Theories in second language acquisition* (pp. 83-104). Routledge.
- [17] Taie, M. (2014). Skill acquisition theory and its important concepts in SLA. *Theory and practice in language studies*, 4(9), 1971.
- [18] Anderson, J. R. (2013). *The adaptive character of thought*. Psychology Press.
- [19] DeKeyser, R., & Criado, R. (2012). Automatization, skill acquisition, and practice in second language acquisition. *The encyclopedia of applied linguistics*, 323-331.
- [20] Celce-Murcia, M., Brinton, D., & Goodwin, J. M. (1996). *Teaching pronunciation: A reference for teachers of English to speakers of other languages*. Cambridge University Press.
- [21] Anderson, J. R. (1982). Acquisition of cognitive skill. *Psychological review*, 89(4), 369.
- [22] Ellis, R. (2006). Current issues in the teaching of grammar: An SLA perspective. *TESOL quarterly*, 40(1), 83-107.
- [23] Dłaska, A., & Krekeler, C. (2013). The short-term effects of individual corrective feedback on L2 pronunciation. *System*, 41(1), 25-37.
- [24] Stufflebeam, D. L. (1972). Benjamin S. Bloom, J. Thomas Hastinos, and George F. Madaus Handbook on Formative and Summative Evaluation of Student Learning. New York: McGraw-Hill Book Company, 1971. Pp. x+ 913 \$12.50. *Psychometrika*, 37(4), 487-489.
- [25] Sadler, D. R. (1989). Formative assessment and the design of instructional systems. *Instructional science*, 18(2), 119-144.
- [26] William, D. (2011). Formative assessment: Definitions and relationships. *Studies in Educational Evaluation*, 37(1), 3-14.

- [27] Saito, K., & Lyster, R. (2012). Effects of form-focused instruction and corrective feedback on L2 pronunciation development of /ɹ/ by Japanese learners of English. *Language learning*, 62(2), 595-633.
- [28] Wisniewski, B., Zierer, K., & Hattie, J. (2020). The power of feedback revisited: A meta-analysis of educational feedback research. *Frontiers in psychology*, 10, 487662.
- [29] Flavell, J. H. (1979). Metacognition and cognitive monitoring: A new area of cognitive-developmental inquiry. *American psychologist*, 34(10), 906.
- [30] Zhang, D., & Zhang, L. J. (2019). Metacognition and self-regulated learning (SRL) in second/foreign language teaching. In *Second handbook of English language teaching* (pp. 883-897). Cham: Springer International Publishing.
- [31] Franco, H., Neumeyer, L., Kim, Y., & Ronen, O. (1997, April). Automatic pronunciation scoring for language instruction. In *1997 IEEE international conference on acoustics, speech, and signal processing* (Vol. 2, pp. 1471-1474). IEEE.
- [32] Ronen, O., Neumeyer, L., & Franco, H. (1997). Automatic detection of mispronunciation for language instruction. In *Proc. Eurospeech 1997* (pp. 649-652).
- [33] Neumeyer, L., Franco, H., Digalakis, V., & Weintraub, M. (2000). Automatic scoring of pronunciation quality. *Speech communication*, 30(2-3), 83-93.
- [34] Strik, H., Neri, A., & Cucchiarini, C. (2008). Speech technology for language tutoring.
- [35] Witt, S. M., & Young, S. J. (2000). Phone-level pronunciation scoring and assessment for interactive language learning. *Speech communication*, 30(2-3), 95-108.
- [36] Harrison, A. M., Lo, W. K., Qian, X., & Meng, H. (2009, September). Implementation of an extended recognition network for mispronunciation detection and diagnosis in computer-assisted pronunciation training. In *SLaTE* (pp. 45-48).
- [37] Franco, H., Ferrer, L., & Bratt, H. (2014, May). Adaptive and discriminative modeling for improved mispronunciation detection. In *2014 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 7709-7713). IEEE.
- [38] Mao, S., Wu, Z., Li, R., Li, X., Meng, H., & Cai, L. (2018, April). Applying multitask learning to acoustic-phonemic model for mispronunciation detection and diagnosis in L2 English speech. In *2018 IEEE International Conference on*

- Acoustics, Speech and Signal Processing (ICASSP)* (pp. 6254-6258). IEEE.
- [39] Mao, S., Li, X., Li, K., Wu, Z., Liu, X., & Meng, H. (2018, April). Unsupervised discovery of an extended phoneme set in 12 english speech for mispronunciation detection and diagnosis. In *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 6244-6248). IEEE.
 - [40] El Kheir, Y., Ali, A., & Chowdhury, S. A. (2023). Automatic pronunciation assessment-a review. *Findings of the Association for Computational Linguistics: EMNLP 2023*, 8304-8324.
 - [41] Feng, Y., Fu, G., Chen, Q., & Chen, K. (2020, May). SED-MDD: Towards sentence dependent end-to-end mispronunciation detection and diagnosis. In *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 3492-3496). IEEE.
 - [42] Wu, M., Li, K., Leung, W. K., & Meng, H. (2021, August). Transformer Based End-to-End Mispronunciation Detection and Diagnosis. In *Interspeech* (pp. 3954-3958).
 - [43] Kim, E., Jeon, J. J., Seo, H., & Kim, H. (2022). Automatic pronunciation assessment using self-supervised speech representation learning. *arXiv preprint arXiv:2204.03863*.
 - [44] Yan, B. C., & Chen, B. (2021, August). End-to-end mispronunciation detection and diagnosis from raw waveforms. In *2021 29th European Signal Processing Conference (EUSIPCO)* (pp. 61-65). IEEE.
 - [45] Alrashoudi, N., Al-Khalifa, H., & Alotaibi, Y. (2025). Improving mispronunciation detection and diagnosis for non-native learners of the Arabic language. *Discover Computing*, 28(1), 1.
 - [46] Phan, N., Kuronen, M., Kautonen, M., Ullakonoja, R., von Zansen, A., Getman, Y., ... & Kurimo, M. (2025). Mispronunciation Detection Without L2 Pronunciation Dataset in Low-Resource Setting: A Case Study in Finland Swedish. *arXiv preprint arXiv:2506.01156*.
 - [47] Bharati, P., Chandra, S., Aitawade, A., Pramanik, D., Gaddamedi, S. P., & Mandal, S. K. D. (2026). A deep neural network-based automatic mispronunciation detection in Bengali accented English speech. *Discover Computing*, 29(1), 71.
 - [48] Scott, N. C. (1948). A study in the phonetics of Fijian. *Bulletin of SOAS*, 12(3-4), 737-752.

- [49] Hopf, S. C., McLeod, S., & Geraghty, P. (2016). A contrastive analysis of the phonologies of two Fiji English dialects: A diagnostic guide for speech – language pathologists. *Speech, Language and Hearing*, 19(2), 96-104.
- [50] Slam, W., Li, Y., & Urouvas, N. (2023). Frontier research on low-resource speech recognition technology. *Sensors*, 23(22), 9096.
- [51] Van den Akker, J. (1999). Principles and methods of development research. In *Design approaches and tools in education and training* (pp. 1-14). Dordrecht: Springer Netherlands.
- [52] Richey, R. C., & Klein, J. D. (2014). *Design and development research: Methods, strategies, and issues*. Routledge.
- [53] Creswell, J. W., & Creswell, J. D. (2017). *Research design: Qualitative, quantitative, and mixed methods approaches*. Sage publications.
- [54] Davis, F. D. (1989). Perceived usefulness, perceived ease of use, and user acceptance of information technology. *MIS quarterly*, 13(3), 319-340.
- [55] Cucchiarini, C., Neri, A., & Strik, H. (2009). Oral proficiency training in Dutch L2: The contribution of ASR-based corrective feedback. *Speech Communication*, 51(10), 853-863.
- [56] Brooke, J. (1996). SUS-A quick and dirty usability scale. *Usability evaluation in industry*, 189(194), 4-7.
- [57] Bangor, A., Kortum, P. T., & Miller, J. T. (2008). An empirical evaluation of the system usability scale. *Intl. Journal of Human – Computer Interaction*, 24(6), 574-594.
- [58] Braun, V., & Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative research in psychology*, 3(2), 77-101
- [59] Amrate, M., & Tsai, P. H. (2025). Computer-assisted pronunciation training: A systematic review. *ReCALL*, 37(1), 22-42.

2. 中文文献

- [1] 马秋武,翟海莹.动态语音教学：国际汉语语音教学的有效手段[J].汉语学习,2024,(01):73-83.
- [2] 魏思,吴奎,竺博,等.语音评测技术助力英语口语教学与评价[J].人工智能,2019,(03): 72-79.DOI:10.16453/j.cnki.issn2096-5036.2019.03.010.

